Moment üreten fonksiyonlar

- Bir X rasgele değişkeninin olasılık dağılımına ait dönüşüm aşağıdaki gibi tanımlanır:

$$M_X(s) = \mathrm{E}[e^{sX}] = \begin{cases} \sum_x e^{sx} p_X(x), & X \sim p_X(x) \text{ ise} \\ \int_{-\infty}^{\infty} e^{sx} f_X(x)\,dx, & X \sim f_X(x) \text{ ise} \end{cases}$$

- Bu dönüşüme moment üreten fonksiyon (moment generating function) denir.
- $s = j\omega$ için ($j = \sqrt{-1}$ ve ω gerçek) dönüşüm, $M_X(j\omega)$, karakteristik fonksiyon (characteristic function) adını alır.
- Monent üreten fonksiyon $M_X(s)$ Laplace dönüşümü
- Karakteristik fonksiyon $M_X(j\omega)$ Fourier dönüşümü ile ilgilidir.

Örnekler

Örnek: $X \sim \text{Bern}(p)$ olsun. $M_X(s) = (1-p) + pe^s$

$$\text{E}[X] = M_X^{(1)}(0) = pe^s\Big|_{s=0} = p$$
$$\text{E}[X^2] = M_X^{(2)}(0) = pe^s\Big|_{s=0} = p$$

Örnek: $X \sim \text{Exp}(\lambda)$ olsun. $M_X(s) = \frac{\lambda}{\lambda - s}$

$$\text{E}[X] = M_X^{(1)}(0) = \frac{\lambda}{(\lambda-s)^2}\Big|_{s=0} = \frac{1}{\lambda}$$
$$\text{E}[X^2] = M_X^{(2)}(0) = \frac{2\lambda}{(\lambda-s)^3}\Big|_{s=0} = \frac{2}{\lambda^2}$$

Örnek: $X \sim \text{N}(\mu, \sigma^2)$, olsun. $M_X(s) = e^{\mu s + \frac{\sigma^2 s^2}{2}}$

$$\text{E}[X] = M_X^{(1)}(0) = (\mu + s\sigma^2)\, e^{\mu s + \frac{\sigma^2 s^2}{2}}\Big|_{s=0} = \mu$$
$$\text{E}[X^2] = M_X^{(2)}(0) = \left((\mu + s\sigma^2)^2 e^{\mu s + \frac{\sigma^2 s^2}{2}} + \sigma^2 e^{\mu s + \frac{\sigma^2 s^2}{2}}\right)\Big|_{s=0} = \sigma^2 + \mu^2$$

El Gamal, 2021

Çoklu rasgele değişkenler

- $X_1, X_2, \ldots, X_n$ aynı olasılık uzayında tanımlanmış ras
- Eğer r.d.'ler ayrık ise ortak okf'leri ile tanımlanabilir

$$p_{X_1,X_2,\ldots,X_n}(x_1, x_2, \ldots, x_n)$$

- Eğer r.d.'ler sürekli ise ortak oyf'leri ile tanımlanabilirler:

$$f_{X_1,X_2,\ldots,X_n}(x_1, x_2, \ldots, x_n)$$

- Marjinal oyf (okf)'ler $\{X_1, X_2, \ldots, X_n\}$'nin bir alt kümesinin ortak oyf'si (okf'si)dir.

- $n = 3$ için marjinal oyf'ler $f_{X_1}(x_1)$, $f_{X_2}(x_2)$, $f_{X_3}(x_1)$, $f_{X_1,X_2}(x_1, x_2)$, $f_{X_1,X_3}(x_1, x_3)$, $f_{X_2,X_3}(x_2, x_3)$.

$$f_{X_1,X_2}(x_1, x_2) = \int_{-\infty}^{\infty} f_{X_1,X_2,X_3}(x_1, x_2, x_3)dx_3$$

El Gamal, 2021

Çoklu rasgele değişkenler

- Koşullu okf/oyf iki r.d.'de olduğu gibi tanımlanır. Örneğin $(X_1, X_2, \dots, X_k)$ verildiğinde $(X_{k+1}, X_{k+2}, \dots, X_n)$

$$f_{X_{k+1},\dots,X_n|X_1,\dots,X_k}(x_{k+1}, \dots, x_n|x_1, \dots, x_k) = \frac{f_{X_1,\dots,X_n}(x_1, \dots, x_n)}{f_{X_1,\dots,X_k}(x_1, \dots, x_k)}$$

- Zincir kuralı: Ortak okf/oyf'yi aşağıdaki gibi ifade edebiliriz:

$$f_{X_1,\dots,X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) f_{X_2|X_1}(x_2|x_1) \cdots f_{X_n|X_1,\dots,X_{n-1}}(x_n|x_1, \dots, x_{n-1})$$

- Genel olarak $X_1, X_2, \dots, X_n$ ortak bdf ile tanımlanabilir:

$$F_{X_1,\dots,X_n}(x_1, \dots, x_n) = P(X_1 \le x_1, \dots, X_n \le x_n)$$

El Gamal, 2021

Bayes kuralı

- $X \sim p_X(x)$ gözlenemeyen işaret, $Y_1, Y_2, \dots, Y_n$ gözlemler olsun. Gözlemlerin bilinmeyen değişkene göre koşullu dağılımı $p_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x)$ biliniyor olsun. Bu durumda bilinmeyen değişkenin sonsal dağılımı Bayes kuralı ile aşağıdaki gibi olur:

$$p_{X|Y_1,\dots,Y_n}(x|y_1, \dots, y_n) = \frac{p_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x)}{\sum_{x' \in \mathcal{X}} p_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x')p_X(x')} p_X(x)$$

- Sürekli rasgele değişkenler için okf'ler oyf'ler ile ve toplam integral ile yer değiştirir:

$$f_{X|Y_1,\dots,Y_n}(x|y_1, \dots, y_n) = \frac{f_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x)}{\int_{-\infty}^{\infty} f_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x)f_X(u)du} f_X(x)$$

- X sürekli ve $Y_1, Y_2, \dots, Y_n$'ler ayrık ise

$$f_{X|Y_1,\dots,Y_n}(x|y_1, \dots, y_n) = \frac{p_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x)}{\int_{-\infty}^{\infty} p_{Y_1,\dots,Y_n|X}(y_1, \dots, y_n|x)f_X(u)du} f_X(x)$$

El Gamal, 2021

Bağımsızlık

- $X_1, X_2, \ldots, X_n$ rasgele değişkenleri eğer ortak okf/oyf/bdf'leri marjinallerin çarpımı şeklinde yazılabiliyorsa bağımsızdır

$$f_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = \prod_{i=1}^{n} f_{X_i}(x_i)$$

- $X_1, X_2, \ldots, X_n$ rasgele değişkenleri bağımsız ve türdeş dağılımlı (independent and identically distributed, i.i.d.) eğer bağımsız ve aynı marjinal dağılıma sahiplerse

$$f_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = \prod_{i=1}^{n} f_X(x_i)$$

Rasgele değişkenlerin istatistiklerinin kestirimi

- İstatistikte ve makine öğrenmesinde ana problemlerden biri rasgele değişkenlerin ortalama, varyans, kovaryans, dağılım gibi istatistiklerinin veriden nasıl kestirileceğidir.

- Örnekler:
- X'in ortalamasını kestirmek için X'in dağılımından bağımsız ve türdeş (i.i.d.) olarak üretilmiş bir eğitim veri kümesi $\{x_i\}_{i=1}^n$ kulan ve örnek ortalamasını hesapla: $\bar{x}_n = \frac{1}{n}\sum_{i=1}^n x_i$

- X'in ikinci momentini kestirmek için : $\bar{x}_n^2 = \frac{1}{n}\sum_{i=1}^n x_i^2$

- $P(X \in A)$ olasılığını kestirmek için $x_i \in A$ iken $y_i = 1$ diğer durumlarda $y_i = 0$ olan bir değişken tanımlayalım. $\overline{P(A)} = \frac{1}{n}\sum_{i=1}^n y_i$

- (X, Y)'in korelasyonunu kestirmek için (X, Y)'in ortak dağılımından üretilmiş bir eğitim veri kümesi $\{x_i, y_i\}_{i=1}^n$ kulanarak korelasyon kestirimini hesapla: $\bar{c}_n = \frac{1}{n}\sum_{i=1}^n x_i y_i$

El Gamal, 2021

Parametre kestirimi

- Bazı durumlarda, rasgele değişkenin dağılımı bir kaç parametre θ ile tanımlanır, örneğin daha önce gördüğümüz popular dağılımlar gibi

r.v.	Parameters
Bern(p)	$\theta = p$
Geom(p)	$\theta = p$
Binom(n, p)	$\theta = (n, p)$
Poisson(λ)	$\theta = \lambda$
Unif$[a, b]$	$\theta = (a, b)$
Exp(λ)	$\theta = \lambda$
N(μ, σ^2)	$\theta = (\mu, \sigma^2)$

- Bu tür parametrik dağılımlar için ilkönce parametrelerini kestirip daha sonra istediğimiz istatistikleri kestirebiliriz.For such parametric distributions, we can estimate

- Parametre kestirimi için bir çok yöntem bulunmaktadır. Bunlardan sadece en büyük olabilirlik (maximum likelihood) kestiriminden bahsedeceğiz.

El Gamal, 2021

En büyük olabilirlik kestirimi (EOK)

- $X \sim p_X(x;\theta)$ ve θ parametresi bilinmiyor olsun.
- θ'yı kestirmek için $p_X(x;\theta)$ dağılımından bağımsız ve türdeş (i.i.d.) olarak üretilmiş eğitim veri kümesi $\{x_i\}_{i=1}^n$ kulanalım .
- En büyük olabilirlik kestiriminde eğitim veri kümesini üreten olabilirliği (likelihood) en büyük yapacak şekilde $\hat{\theta}$ seçilir.

$$L(\theta) = p_{X_1,X_2,\ldots,X_n}(x_1, x_2, \ldots, x_n;\theta), \qquad \left(\text{or } f_{X_1,\ldots,X_n}(x_1,\ldots,x_n;\theta)\right)$$
$$= \prod_{i=1}^{n} p_X(x_i;\theta)$$

- Daha sıklıkla olabilirliğin logaritması (log likelihood) en büyüklenir:

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^{n} \ln p_X(x_i;\theta)$$

El Gamal, 2021

Örnek: Bernoulli parametresinin EOK'si

$X \sim \text{Bern}(p)$ ve p parametresi bilinmiyor olsun.

p'yi $\text{Bern}(p)$ dağılımından bağımsız ve türdeş (i.i.d.) olarak üretilmiş eğitim veri kümesi $\{x_i\}_{i=1}^n$ kulanarak EOK ile bulalım.

$$L(p) = \prod_{i=1}^{n} \text{Bern}(p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}$$

$$\begin{aligned}\ell(p) &= \sum_{i=1}^{n} \ln p^{x_i}(1-p)^{1-x_i} \\ &= \ln p \sum_{i=1}^{n} x_i + \ln(1-p) \sum_{i=1}^{n} (1-x_i) \\ &= n\bar{x} \ln p + (n - n\bar{x}) \ln(1-p)\end{aligned}$$

Burada $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$.

El Gamal 2021

Örnek: Bernoulli parametresinin EOK'si

Olabilirliği en büyük yapan $\hat{p}$'yı bulmak için $\ell(p)$'nin türevini alıp sıfıra eşitleyelim:

$$\frac{d\ell(p)}{dp} = \frac{n\bar{x}}{p} - \frac{n - n\bar{x}}{1-p} = 0$$

$$n\bar{x}(1-p) = (n - n\bar{x})p$$

$$\hat{p} = \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

El Gamal, 2021

Örnek: Gauss parametrelerinin EOK'si

$X \sim \mathrm{N}(\mu, \sigma^2)$ ve $\theta = (\mu, \sigma^2)$ parametreleri bilinmiyor olsun.

(μ, σ^2)'yi $\mathrm{N}(\mu, \sigma^2)$ dağılımından bağımsız ve türdeş (i.i.d.) olarak üretilmiş eğitim veri kümesi $\{x_i\}_{i=1}^n$ kulanarak EOK ile bulalım.

$$L(\mu, \sigma^2) = \prod_{i=1}^{n} \mathrm{N}(\mu, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$\begin{aligned} \ell(\mu, \sigma^2) &= \sum_{i=1}^{n} \ln \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} \\ &= \sum_{i=1}^{n} -\frac{1}{2}\ln 2\pi - \frac{1}{2}\ln \sigma^2 - \frac{(x_i-\mu)^2}{2\sigma^2} \\ &= -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln \sigma^2 - \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^2} \end{aligned}$$

El Gamal, 2021

Örnek: Gauss parametrelerinin EOK'si

Olabilirliği en büyük yapan $\hat{\mu}$ ve $\hat{\sigma}^2$'yı bulmak için $\ell(\mu, \sigma^2)$'nin μ ve σ^2'ye kısmi türevlerini alıp sıfıra eşitleyelim:

$$\frac{\partial \ell(\mu, \sigma^2)}{\partial \mu} = \sum_{i=1}^{n} \frac{x_i - \mu}{\sigma^2} = 0$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

$$\frac{\partial \ell(\mu, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \sum_{i=1}^{n} \frac{(x_i - \mu)^2}{2\sigma^4} = 0$$

$$\frac{n}{\sigma^2} = \sum_{i=1}^{n} \frac{(x_i - \mu)^2}{\sigma^4}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \hat{\mu})^2$$

El Gamal, 2021

Rasgele değişkenlerin toplamının ortalaması

$X_1, X_2, \ldots, X_n$ rasgele değişkenlerinin toplamı $Y = \sum_{i=1}^{n} X_i$ olsun. Toplamlarının ortalaması aşağıdaki gibidir:

$$\mathrm{E}[Y] = \mathrm{E}\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} \mathrm{E}[X_i]$$

Bu basit olgu beklentilerin hesaplanmasını basitleştirir.

Örnek: Binom rasgele değişekeninin ortalaması. $X_1, X_2, \ldots, X_n$ r.d.'leri bağımsız ve türdeş dağılımlı (i.i.d.) $\mathrm{Bern}(p)$ olsun. $Y = \sum_{i=1}^{n} X_i$ bir binom r.d.'nidir.

$$\mathrm{E}[Y] = \sum_{i=1}^{n} \mathrm{E}[X_i] = \sum_{i=1}^{n} p = np$$

El Gamal, 2021

Örnek ortalaması kestiriminin ortalaması

Bağımsız ve türdeş dağılımlı $X_1, X_2, \ldots, X_n$ rasgele değişkenlerinin örnek ortalaması $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$'dir. Örnek ortalamasının beklentisi:

$$\mathrm{E}[\bar{X}_n] = \mathrm{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} \mathrm{E}[X_i]$$

$\mathrm{E}[X] = \mathrm{E}[X_i], i = 1, \ldots, n$ olduğundan.

$$\mathrm{E}[\bar{X}_n] = \mathrm{E}[X]$$

Rasgele değişkenlerin toplamının varyansı

$X_1, X_2, \ldots, X_n$ rasgele değişkenlerinin toplamı $Y = \sum_{i=1}^{n} X_i$ olsun. Toplamlarının ortalaması aşağıdaki gibidir:

$$\mathrm{Var}(Y) = \mathrm{E}[(Y - \mathrm{E}[Y])^2]$$

$$= \mathrm{E}\left[\left(\sum_{i=1}^{n} X_i - \sum_{i=1}^{n} \mathrm{E}[X_i]\right)^2\right]$$

$$= \mathrm{E}\left[\left(\sum_{i=1}^{n} (X_i - \mathrm{E}[X_i])\right)^2\right]$$

$$= \mathrm{E}\left[\left(\sum_{i=1}^{n} (X_i - \mathrm{E}[X_i])\right)\left(\sum_{j=1}^{n} (X_j - \mathrm{E}[X_j])\right)\right]$$

$$= \mathrm{E}\left[\sum_{i=1}^{n}\sum_{j=1}^{n} (X_i - \mathrm{E}[X_i])(X_j - \mathrm{E}[X_j])\right]$$

$$= \sum_{i=1}^{n}\sum_{j=1}^{n} \mathrm{E}[(X_i - \mathrm{E}[X_i])(X_j - \mathrm{E}[X_j])]$$

El Gamal 2021

Rasgele değişkenlerin toplamının varyansı

$X_1, X_2, \dots, X_n$ rasgele değişkenlerinin toplamı $Y = \sum_{i=1}^{n} X_i$ olsun. Toplamlarının ortalaması aşağıdaki gibidir:

$$\mathrm{Var}(Y) = \sum_{i=1}^{n}\sum_{j=1}^{n} \mathrm{E}\big[(X_i - \mathrm{E}[X_i])(X_j - \mathrm{E}[X_j])\big]$$

$$= \sum_{i=1}^{n} \mathrm{Var}(X_i) + \sum_{i=1}^{n}\sum_{j\neq i}^{n} \mathrm{Cov}(X_i, X_j)$$

Eğer rasgele değişkenler bağımsızsa tüm $j \neq i$ için $\mathrm{Cov}(X_i, X_j) = 0$ olacağından

$$\mathrm{Var}(Y) = \sum_{i=1}^{n} \mathrm{Var}(X_i)$$

Örnek: Binom rasgele değişekeninin varyansı. $X_1, X_2, \dots, X_n$ r.d.'leri bağımsız ve türdeş dağılımlı (i.i.d.) $\mathrm{Bern}(p)$ olsun. $Y = \sum_{i=1}^{n} X_i$ bir binom r.d.'nidir.

$$\mathrm{Var}(Y) = \sum_{i=1}^{n} \mathrm{Var}(X_i) = \sum_{i=1}^{n} p(1-p) = np(1-p)$$

El Gamal 2021

Örnek ortalaması kestiriminin varyansı

Bağımsız ve türdeş dağılımlı $X_1, X_2, \dots, X_n$ rasgele değişkenlerinin örnek ortalaması $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$'dir. Örnek ortalamasının beklentisi:

$$\begin{aligned}
\mathrm{Var}(\bar{X}_n) &= \mathrm{E}[(\bar{X}_n - \mathrm{E}[\bar{X}_n])^2] = \mathrm{E}[(\bar{X}_n - \mathrm{E}[X])^2] \\
&= \mathrm{E}\left[\left(\frac{1}{n}\sum_{i=1}^{n} X_i - \mathrm{E}[X]\right)^2\right] = \mathrm{E}\left[\left(\frac{1}{n}\sum_{i=1}^{n} (X_i - \mathrm{E}[X])\right)^2\right] \\
&= \frac{1}{n^2}\left(\sum_{i=1}^{n} \mathrm{Var}(X_i) + \sum_{i=1}^{n}\sum_{j\neq i}^{n} \mathrm{Cov}(X_i, X_j)\right) \\
&= \frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(X_i)
\end{aligned}$$

$\mathrm{Var}(X_i) = \mathrm{Var}(X),\ i = 1, \dots, n$ olduğundan.

$$\mathrm{Var}(\bar{X}_n) = \frac{\mathrm{Var}(X)}{n}$$

El Gamal, 2021

Eşitsizlikler ve limit teoremleri

- Eşitsizlikler ve limit teoremleri olasılıkta önemli konulardan biridir.
- Teorik olmalarına karşın birçok uygulamaya sahiptirler. Örneğin
  - İstatistik ve makine öğrenmesinde bir kestirimcinin başarımının belirlenmesinde,
  - Bilgisayar bilimlerinde rasgele algoritmaların başarımlarının analiz edilmesinde,
  - Bilgi teorisinde güvenilir haberleşmenin limitlerinin belirlenmesinde kullanılabilirler.
- Bu derste bu konulara derinlemesine değil sadece yüzeysel olarak bakacağız.

Eşitsizlikler

- Eşitsizlikler ilgilenilen olayın olasılığın hesaplanmasının zor veya elverişsiz olduğu durumlarda kullanılır.
- Limit teoremlerinin kurulmasında edilmesinde önemli rol oynarlar.
- Eşitsizliklere bir örnek daha önce görmüş olduğumuz olayların birleşiminin sınırıdır:

- $A_1, A_2, \ldots, A_n$ olayları verilmiş olsun bunların birleşiminin olasılığını aşağıdaki gibi sınırlandırabiliriz:

$$P\left(\bigcup_{i=1}^{n} A_i\right) \leq \sum_{i=1}^{n} P(A_i)$$

Bir çok durumda X r.d.'ninin dağılımını bilemeyiz ama $\{X > a\}$ gibi bir olayın olasılığını bilmek isteyebiliriz. Markov eşitsizliği bize bu tür durumlarda yardımcı olur.

Markov eşitsizliği

- $X \geq 0$ rasgele değişkeni bir bölgede yaşayan bir insanın yaşı olsun. Bu bölgede yaşayan insanların yaş ortalaması $\mathrm{E}[X] = 35$ ise nüfusun ne kadarı 70 yaş ve üzerindedir.
- Sadece ortalamayı bilerek bu spruyu tam olarak cevaplayamayız ama nüfusundan yarısından azı 70 yaş ve üzerindedir diyebiliriz

$$P\{X \geq 70\} \leq \frac{1}{2}$$

- Bu Markov eşitizliğinin bir uygulamasıdır.

Markov eşitsizliği:

$X \geq 0$ rasgele değişkeni pozitif ve sonlu bir ortalaması $\mathrm{E}[X]$ olsun. Bu durumda $a > 1$ sayısı için

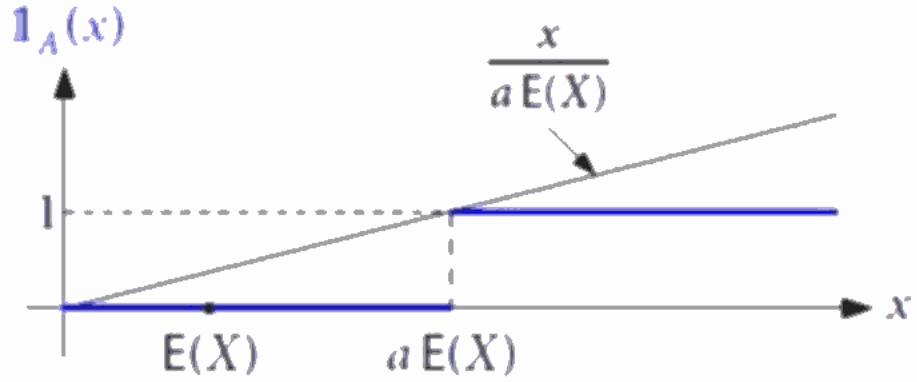
$$P\{X \geq a\mathrm{E}[X]\} \leq \frac{1}{a}$$

El Gamal, 2021

Markov eşitsizliği

İspat: $A \triangleq \{x \geq a\mathrm{E}[X]\}$ kümesi için bir gösterge fonksiyonu tanımlayalım.

$$I_A(x) = \begin{cases} 1, & x \geq a\mathrm{E}[X] \\ 0, & \text{diğer d.} \end{cases}$$



Şekilden aşağıdaki eşitsizliği yazabiliriz:

$$I_A(x) \leq \frac{x}{a\mathrm{E}[X]}$$

Her iki tarafın beklentisini alırsak

$$\mathrm{E}[I_A(x)] \leq \mathrm{E}\left[\frac{x}{a\mathrm{E}[X]}\right]$$

El Gamal, 2021

Markov eşitsizliği

$$\mathrm{E}[I_A(x)] = \int_0^{\infty} I_A(x) f_X(x) dx = \int_{a\mathrm{E}[X]}^{\infty} f_X(x) dx = P\{X \geq a\mathrm{E}[X]\}$$

En son elde ettiğimiz eşitsizlikte yerine yazarsak

$$P\{X \geq a\mathrm{E}[X]\} \leq \frac{\mathrm{E}[x]}{a\mathrm{E}[X]}$$

$$P\{X \geq a\mathrm{E}[X]\} \leq \frac{1}{a}$$

Markov eşitsizliği çok geniş olabilir.

Örnek: $X \geq 0$ ve $\mathrm{E}[X] = 1$ olsun. Markov eşitsizliğine göre

$$P\{X \geq 10\} \leq \frac{1}{10}$$

Markov eşitsizliği

- Markov eşitsizliği çok geniş bir sınır verebilir.
- Örnek: $X \geq 0$ ve $\mathrm{E}[X] = 1$ olsun. Markov eşitsizliğine göre

$$P\{X \geq 10\} \leq \frac{1}{10}$$

Şimdi X'in bir üstel dağılıma sahip olduğunu kabul edelim. $X \sim \mathrm{Exp}(1)$ ise $\mathrm{E}[X] = 1$ olur. $P\{X \geq 10\}$ olasılığını kesin olarak hesaplayabiliriz.

$$P\{X \geq 10\} = e^{-10} \approx 4.55 \times 10^{-5} \ll 0.1$$

- Buna rağmen X r.d. hakkında bildiğimiz tek şey ortalaması ise Markov eşitsizliği elde edebileceğimiz en iyi sınırdır.

Chebyshev eşitsizliği

- Markov eşitsizliği $X \geq 0$ r.d.'nin kuyruk olasılığını ortalamasını kullanarak sınırlandırır.
- Chebyshev eşitsizliği $X \geq 0$ r.d.'nin kuyruk olasılığını ortalamasını ve varyansını kullanarak sınırlandırır.

$X \geq 0$ rasgele değişkeninin sonlu bir ortalaması $\mathrm{E}[X]$ ve varyansı σ_X^2 olsun. Bu durumda $a > 1$ sayısı için

$$P\{|X - \mathrm{E}[X]| \geq a\sigma_X\} \leq \frac{1}{a^2}$$

- İspat: $Y = (X - \mathrm{E}[X])^2$ olarak tanımlarsak $X \geq 0$ ve $\mathrm{E}[Y] = \sigma_X^2$ olur. Y için Markov eşitsizliğini yazalım:

$$P\{Y \geq a^2\mathrm{E}[Y]\} \leq \frac{1}{a^2}$$

$$P\{(X - \mathrm{E}[X])^2 \geq a^2\sigma_X^2\} \leq \frac{1}{a^2}$$

$$P\{|X - \mathrm{E}[X]| \geq a\sigma_X\} \leq \frac{1}{a^2}$$

Chebyshev eşitsizliği

- Örnek: X bir entegre devrenin bir parametresi olsun. X'in ortalaması $\mathrm{E}[X]$ ve varyansı σ_X^2 olsun. Parametre X ile ortalaması arasındaki mesafe $3\sigma_X$ veya daha fazla ise entegre devre standard dışı (out-of-spec) oluyor. Entegre devrenin stardart dışı olma olasılığı, $P\{|X - \mathrm{E}[X]| \geq 3\sigma_X\}$, nedir?
-

  Chebyshev eşitsizliği kullanarak

$$P\{|X - \mathrm{E}[X]| \geq 3\} \leq \frac{1}{9}$$

- Chebyshev eşitsizliği de çok geniş bir sınır verebilir.

Chebyshev eşitsizliği

- Chebyshev eşitsizliği de çok geniş bir sınır verebilir.
- Örnek: $X \geq 0$, $\mathrm{E}[X] = 0$ ve $\sigma_X^2 = 1$ olsun. Chebyshev eşitsizliğine göre

$$P\{|X| \geq 3\} \leq \frac{1}{9}$$

Şimdi X'in bir Gauss dağılıma sahip olduğunu kabul edelim. $X \sim \mathrm{N}(0,1)$ ise $\mathrm{E}[X] = 0$ ve $\sigma_X^2 = 1$'dir. $P\{|X| \geq 3\}$ olasılığını kesin olarak hesaplayabiliriz.

$$P\{|X| \geq 3\} = P\{X \geq 3\} + P\{X \leq -3\} = 2\Phi(-3) = 2\big(1 - \Phi(3)\big) \approx 2 \times 10^{-3} \ll \frac{1}{9}$$

- Buna rağmen X r.d. hakkında sadece ortalama ve varyansı biliyorsak Chebyshev eşitsizliği elde edebileceğimiz en iyi sınırdır.

El Gamal, 2021