Ders 7

İki ayrık rasgele değişen $(X,Y) \in X \times Y$ ortak olkf ile tam olarak tanımlanabilir.

$p_{X,Y}(x,y) = P\{X=x, Y=y\}$

Özellikleri:
1. $p_{X,Y}(x,y) \geq 0$
2. $\sum_{(x,y)\in X\times Y} p_{X,Y}(x,y) = 1$

Bir tablo verilirse $p_{X,Y}(x,y)$ Hesaplanmak istenen koşul incelenir x veya yerine konarak tablodan değer alınır.

Örnek

$P(X+Y=4) = p_{X,Y}(1,3) + p_{X,Y}(2,2) + p_{X,Y}(3,1)$

$x \in [1,4]$, $y \in [1,4]$

Marjinal olkf

$p_X(x) = \sum_{y\in Y} p_{X,Y}(x,y)$ → y boyunca toplam

$p_Y(y) = \sum_{x\in X} p_{X,Y}(x,y)$ → x boyunca toplam

Koşullu olkf

X'in koşullu olkf'si:

$p_{X|Y}(x|y) = \frac{p_{X,Y}(x,y)}{p_Y(y)}$

Y'nin koşullu olkf'si:

$p_{Y|X}(y|x) = \frac{p_{X,Y}(x,y)}{p_X(x)}$

Sabit bir x için

$\sum_{y\in Y} p_{Y|X}(y|x) = 1$

Zincir kuralı:

$p_{X,Y}(x,y) = p_X(x)\, p_{Y|X}(y|x)$

Bayes kuralı:

$p_{X|Y}(x|y) = \frac{p_{Y|X}(y|x)}{\sum_{x'\in X} p_{Y|X}(y|x')\, p_X(x')}\, p_X(x)$

Bağımsızlık:

X ve Y ayrık rasgele değişkenleri aşağıdaki şartı sağlıyorsa bağımsızdır

$p_{X,Y}(x,y) = p_X(x)\, p_Y(y)$

X ve Y bağımsızsa

$p_{Y|X}(y|x) = p_Y(y)$ ve

$p_{X|Y}(x|y) = p_X(x)$'dir

İki sürekli rasgele değişken: Ortak olf

İki sürekli rasgele değişen $(X,Y) \in \mathbb{R}^2$ ortak olf $f_{X,Y}(x,y)$ ile tam olarak tanımlanabilir

$$P\{(X,Y)\in B\} = \int_{(x,y)\in B} f_{X,Y}(x,y)\,dx\,dy$$

Örneğin dikdörtgen bir alan için

$$P\{a<X\leq b, c<Y\leq d\} = \int_c^d \int_a^b f_{X,Y}(x,y)\,dx\,dy$$

Özellikleri:

1. $f_{X,Y}(x,y) \geq 0$
2. $\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx\,dy = 1$ //

* Olf bir olasılık değeri olasılıkla ilişkisi aşağıdaki gibidir

$$P\{x<X\leq x+\Delta x, y<Y\leq y+\Delta y\} \approx f_{X,Y}(x,y)\,\Delta x\,\Delta y$$

örnek

$$P\{X \geq \tfrac{1}{2} Y\} = \iint_{\{(x,y): x\geq \frac{1}{2}y\}} f_{X,Y}(x,y)\,dx\,dy$$

İkikatlı integral

Marjinal olf

X'in marjinal olfsi:

$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dy$

Y'nin marjinal olfsi:

$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx$

Ders 8

Y'nin koşullu olf'si

$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}$

X'in koşullu olf'si

$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$

Sabit bir x için $f_{Y|X}(y|x)$

Y'nin olf'sidir. $f_{Y|X}(y|x) \geq 0$ ve integrali 1'e eşit.

$$\int_{-\infty}^{\infty} f_{Y|X}(y|x)\,dy = 1$$

Zincir kuralı: $f_{X,Y}(x,y) = f_X(x)\, f_{Y|X}(y|x)$

Bayes kuralı: $f_{X|Y}(x|y) = \frac{f_{Y|X}(y|x)}{\int_{-\infty}^{\infty} f_{Y|X}(y|x) f_X(x)\,dx} f_X(x)$

$f_{X,Y}(x,y) = f_X(x) f_Y(y) \Rightarrow$ X ve Y bağımsızdır

X ve Y bağımsızsa

$f_{Y|X}(y|x) = f_Y(y)$ ve $f_{X|Y}(x|y) = f_X(x)$'dir

Bir ayrık ve bir sürekli rasgele değişken

X olkf'si $p_X(x)$ olan bir ayrık rasgele değişken olsun. Her $X=x$ için, $p_X(x) \neq 0$ koşullu olf'si $f_{Y|X}(y|x)$ olan Y sürekli değişkeni olsun.

$\Rightarrow f_Y(y) = \sum_x f_{Y|X}(y|x)\, p_X(x)$

X'in Y'ye göre sonsal olkf'si de limit durumunda aşağıdaki gibi bulunabilir.

$$p_{X|Y}(x|y) = \frac{f_{Y|X}(y|x)}{f_Y(y)}\, p_X(x) = \frac{f_{Y|X}(y|x)}{\sum_{x'} f_{Y|X}(y|x') p_X(x')}\, p_X(x)$$

Toplamsal Gauss gürültü kanalı



Gönderilen bit ayrık bir rasgele değişken olarak modellenir

$$X = \begin{cases} x_0, & \text{olasılıkla } p \\ x_1, & \text{1-p olasılıkla} \end{cases}$$

- Toplamsal gürültü bir Gauss r.dd'ir $Z \sim N(0,\sigma_z^2)$
- Alınan işaret $Y = X+Z$ şeklindedir ve burada X ve Z bağımsızdır

Ortak bdf (birikimli dağılım fonksiyonu)

İki r.d (X,Y) ortak bdf $F_{X,Y}(x,y)$ ile tam olarak tanımlanabilir.

$F_{X,Y}(x,y) = P\{X\leq x, Y\leq y\}$, $(x,y) \in (-\infty,\infty)$

Özellikleri:

- $F_{X,Y}(x,y) \geq 0$
- $x_1 \leq x_2$ ve $y_1 \leq y_2$ olmak üzere her zaman $F_{X,Y}(x_1,y_1) \leq F_{X,Y}(x_2,y_2)$
- $\lim_{x,y\to\infty} F_{X,Y}(x,y) = 1$
- $\lim_{y\to\infty} F_{X,Y}(x,y) = F_X(x)$ ve $\lim_{x\to\infty} F_{X,Y}(x,y) = F_Y(y)$
- $\lim_{y\to-\infty} F_{X,Y}(x,y) = 0$ ve $\lim_{x\to-\infty} F_{X,Y}(x,y) = 0$

** Bir olayın olasılığı ortak bdf'ik belirlenebilir

Örnek: $\{(x,y): a<x\leq b, c<y\leq d\}$ olayının olasılığı



$P\{a<X\leq b, c<Y\leq d\} = F_{X,Y}(b,d) - F_{X,Y}(a,d) - F_{X,Y}(b,c) + F_{X,Y}(a,c)$

(X,Y) rasgele değişkenleri sürekli ise

$F_{X,Y}(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{X,Y}(u,v)\,dv\,du$

$f_{X,Y}(x,y) = \frac{\partial F_{X,Y}(x,y)}{\partial x\,\partial y}$

$F_{X,Y}(x,y) = F_X(x)\, F_Y(y)$

Ders 9

Bağımsız iki ayrık r.d.nin toplamı

X ve Y bağımsız iki ayrık r.d ve $W = X+Y$ olsun. W'nun dağılımı nedir?

$X \sim p_X(x)$ ve $Y \sim p_Y(y)$ tam sayı-değerli r.d'ler olsun. Burdaki toplamların olkf'si:

$$p_W(w) = \sum_{x=-\infty}^{\infty} p_X(x)\, p_Y(w-x)$$ [iki olkf'nin ayrık konvolüsyonudur]

$X \sim \text{Poisson}(\lambda_1)$ ve $Y \sim \text{Poisson}(\lambda_2)$ bağımsız iki r.d ise bunların toplamı W'nunda olkf'sini bulunuz

$$p_W = \sum_{x=-\infty}^{\infty} p_X(x)\, p_Y(w-x)$$
$$= \sum_{x=0}^{w} p_X(x)\, p_Y(w-x)$$
$$= \sum_{x=0}^{w} \frac{\lambda_1^x}{x!} e^{-\lambda_1} \cdot \frac{\lambda_2^{(w-x)}}{(w-x)!} e^{-\lambda_2}$$
$$= \frac{(\lambda_1+\lambda_2)}{w!} e^{-(\lambda_1+\lambda_2)} \sum_{x=0}^{w} \frac{w!}{x!(w-x)!} \left(\frac{\lambda_1}{\lambda_1+\lambda_2}\right)^x \left(\frac{\lambda_2}{\lambda_1+\lambda_2}\right)^{w-x}$$ (1)

$$p_W(w) = \frac{(\lambda_1+\lambda_2)^w}{w!} e^{-(\lambda_1+\lambda_2)}$$

Bağımsız iki sürekli r.d.nin toplamı

$$f_W(w) = \int_{-\infty}^{\infty} f_X(x)\, f_Y(w-x)\,dx = \int_{-\infty}^{\infty} f_Y(w-x) f_X(x)\,dx$$

- $X \sim N(\mu_1,\sigma_1^2)$ ve $Y \sim N(\mu_2,\sigma_2^2)$ bağımsız olsun.
- $W = X+Y \sim N(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$ olarak bulunur

Beklenen değer

- $X \sim p_X(x)$ ayrık bir r.d ve $g(x)$, x'in bir fonksiyonu olsun.

$$E[g(X)] = \sum_{x\in X} g(x) p_X(x)$$

- Sürekli r.d. $X \sim f_X(x)$ için $g(X)$'in beklentisi

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x)\,dx$$

Beklenti doğrusaldır

$E[ag_1(x) + bg_2(x)] = aE[g_1(x)] + bE[g_2(x)]$

$g(x) = c$, bir sabit ise, $E[g(x)] = c$

$\text{Var}(aX+b) = a^2 \text{Var}(X)$

Korelasyon ve kovaryans

$(X,Y) \sim f_{X,Y}(x,y)$ ve $g(x,y)$ x ve y'nin bir fonksiyonu olsun. $g(X,Y)$'nin beklentisi aşağıdaki gibi tanımlanır.

$$E[g(X,Y)] = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x,y) f_{X,Y}(x,y)\,dx\,dy$$

Korelasyon $= E[XY]$

$\text{Cov}(X,Y) = E[XY] - E[X]E[Y]$

Eğer $X=Y$ ise

$\text{Cov}(X,Y) = \text{Var}(X)$

Eğer $\text{Cov}(X,Y) = 0$ ise

X ve y bir birinden ilişkisizdir ve $E[XY] = E[X]E[Y]$

$\text{Var}(X) = E[X^2] - (E[X])^2$

Korelasyon katsayısı

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y}$$

X ve Y ilişkisizse, $\text{Cov}(X,Y) = 0$, $\rho_{X,Y} = 0$ olur.

- $-1 \leq \rho_{X,Y} \leq 1$'dir.
- Eğer $\rho_{X,Y} = \pm 1$ ise $\frac{X-E[X]}{\sigma_X} = \pm \frac{Y-E[Y]}{\sigma_Y}$ doğrusal bir fonksiyonu ise $\rho_{X,Y} = \pm 1$ olur.

* $\rho_{X,Y}$ bize Y'in Y'nin bir doğrusal fonksiyonu olarak ne kadar iyi kestirilebileceğini bilgisini verir.

Ders 9 Devamı

Koşullu beklenti

İki sürekli rasgele değişken $(X,Y) \sim f_{X,Y}(x,y)$ olsun

ve $f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$

X'in Y'ye göre olası

$\Rightarrow$ Herhangi bir $g(x,y)$ fonksiyonun $f_{X|Y}(x|y)$'ye göre beklentisi aşağıdaki gibi tanımlanabilir.

$$E[g(X,Y)|Y=y] = \int_{-\infty}^{\infty} g(x,y) f_{X|Y}(x|y)\,dx$$

$g(x,y)=x$

$$\Rightarrow E[X|Y=y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y)\,dx$$

Bir rasgele değişken olarak koşullu beklenti

- Koşullu beklenti $E[g(X,Y)|Y=y]$ y'nin bir fonksiyonudur. $E[g(X,Y)|Y]$ beklenen değeri Y rasgele değişkenin bir fonksiyonu olduğu için bir rasgele değişkendir.

$E[X|Y] = Z = \frac{1-Y}{2}$ 'nin olasılığı bulmak için Y'nin doğrusal bir fonksiyonu, $Z=aY+b$, olasılığı için bulduğumuz formülü kullanabiliriz

$$Z = aY+b \Rightarrow f_Z = \frac{1}{|a|} f_Y\left(\frac{z-b}{a}\right)$$

Koşullu beklentinin ortalaması

$$E_Y[E[g(X,Y)|Y]] =$$

$$= \int_{-\infty}^{\infty} E[g(X,Y)|Y=y] f_Y(y)\,dy$$

örnek $E_Y\left[\frac{1-Y}{2}\right] = \int_0^1 \frac{1-y}{2} \underbrace{2(1-y)}_{f_Y} dy = \frac{1}{3}$

Yenilenen beklenti

$$E_Y[E_{X|Y}[g(X,Y)|Y]] = E[g(X,Y)]$$

Burada $E_{X|Y}$, $f_{X|Y}(x|y)$'ye göre beklentidir.

koşullu varyans

(X,Y) o.d'leri için $\{Y=y\}$ olarak verildiğinde X'in koşullu varyansı aşağıdaki gibi tanımlanır.

$$Var(X|Y) = E[X^2|Y] - (E[X|Y])^2$$

Moment üreten fonksiyonlar

- Bir X rasgele değişkenin olasılık dağılımına ait dönüşüm aşağıdaki gibi tanımlanır:

$$M_X(s) = E[e^{sX}] = \begin{cases} \sum_x e^{sx} p_X(x), & X \sim p_X(x) \text{ ise} \\ \int_{-\infty}^{\infty} e^{sx} f_X(x)\,dx, & X \sim f_X(x) \text{ ise} \end{cases}$$

- Bu dönüşüme moment üreten fonksiyon denir
- $s=jw$ için ($j=\sqrt{-1}$ ve w gerçek) dönüşüm, $M_X(jw)$ karakteristik fonksiyon adını alır.

$M_X(s)$ Laplace $\quad$ $M_X(jw)$ Fourier

Örnek $X \sim Bern(p)$ olsun. $p_X(1)=p$ $p_X(0)=1-p$

$$M_X(s) = ? = E[e^{sX}] = \sum_{k=0}^{1} e^{sk} p_X(k)$$

$$= (1-p) + pe^s$$

Örnek: $X \sim Poisson(\lambda)$, olsun

$$p_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k=0,1,2,\dots$$

$$M_X(s) = E[e^{sX}] = \sum_{k=0}^{\infty} e^{sk} p_X(k)$$

$$= \sum_{k=0}^{\infty} e^{sk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(e^s\lambda)^k}{k!}$$

$$= e^{-\lambda} e^{e^s\lambda} = \boxed{e^{\lambda(e^s-1)}}$$

Örnek: $X \sim Exp(\lambda)$ olsun

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{diğerd} \end{cases}$$

$$M_X(s) = E[e^{sX}] = \int_{-\infty}^{\infty} e^{sx} f_X(x)\,dx$$

$$= \int_0^{\infty} e^{sx} \lambda e^{-\lambda x}\,dx = \int_0^{\infty} \lambda e^{(s-\lambda)x}\,dx$$

$$= \lambda \left(\frac{e^{(s-\lambda)x}}{s-\lambda} \Big|_0^{\infty} \right) \quad s-\lambda < 0$$

$$= \lambda \left(-\frac{1}{s-\lambda}\right) = \frac{\lambda}{\lambda - s}$$

Örnek: $X \sim N(\mu, \sigma^2)$ olsun

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$M_X(s) = \int_{-\infty}^{\infty} e^{sx} \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{(x-\mu)^2}{2\sigma^2}} dx$$

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x^2 - 2\mu x - 2\sigma^2 sx + \mu^2)}{2\sigma^2}} dx$$

$$= e^{\mu s + \frac{\sigma^2 s^2}{2}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{(x-(\mu+\sigma^2))^2}{2\sigma^2}} dx$$

$$= e^{\mu s + \sigma^2 \frac{s^2}{2}}$$

Türev üreten fonksiyonun özellikleri

$X \sim p_X(x)$ olsun. $M_X(s)$'nin s'ye göre birinci dereceden türevi:

$$M_X^{(1)}(s) = \frac{d}{ds} M_X(s) = \frac{d}{ds} \sum_x e^{sx} p_X(x)$$

$$= \sum_x x e^{sx} p_X(x)$$

Bu türevin $s=0$'daki değeri bize birinci momenti verir:

$$M_X^{(1)}(0) = \sum_x x p_X(x) = E[X]$$

Türev almayı tekrar tekrar alırsak

$$M_X^{(k)}(0) = E[X^k]$$

$$\frac{d^k}{ds^k} M_X(s) \Big|_{s=0} = \sum_x x^k p_X(x)$$

Ders 10

Çoklu rasgele değişkenler

$X_1, X_2, \dots, X_n$ aynı olasılık uzayında tanımlanmış rasgele değişkenler olsun

Ayrık ise ortak olk

$p_{X_1,X_2,\dots,X_n}(x_1,x_2,\dots,x_n)$ şeklinde tanımlanır

Sürekli ise ortak oyf

$f_{X_1,X_2,\dots,X_n}(x_1,x_2,\dots,x_n)$

- Marjinal oyf'ler (olk'ler) $\{X_1, X_2, \dots X_n\}$'in bir alt kümesinin ortak oyf'sidir.

- $n=3$ için marjinal oyf'ler

$f_{X_1}(x_1), f_{X_2}(x_2), f_{X_3}(x_3), f_{X_1,X_2}(x_1,x_2)$

$f_{X_1,X_3}(x_1,x_3), f_{X_2,X_3}(x_2,x_3)$

$$f_{X_1,X_2}(x_1,x_2) = \int_{-\infty}^{\infty} f_{X_1,X_2,X_3}(x_1,x_2,x_3)\,dx_3$$

oyf olk, zincir kuralı, bdf, bayes dezalış ic

Bağımsızlık

$X_1, X_2, \dots, X_n$ rasgele değişkenleri eğer ortak olk/oyf/bdf'leri marjinallerin çarpımı şeklinde yazılabiliyorsa bağımsız

$$f_{X_1,\dots,X_n}(x_1,\dots,x_n) = \prod_{i=1}^{n} f_{X_i}(x_i)$$

$X_1, X_2, \dots X_n$ rasgele değişkenleri bağımsız ve türdeş dağılımlı, eğer bağımsız ve aynı marjinal dağılıma sahiplerse

$$f_{X_1,\dots,X_n}(x_1,\dots,x_n) = \prod_{i=1}^{n} f_X(x_i)$$

Rasgele değişkenlerin istatistiklerinin kestirimi

X'in ortalamasını kestirmek için

$$\hat{X}_n = \frac{1}{n} \sum_{i=1}^{n} x_i$$

X'in ikinci momentini kestirmek için:

$$\hat{X}_n^2 = \frac{1}{n} \sum_{i=1}^{n} x_i^2$$

$P(X \in A)$ olasılığını kestirmek için $x_i \in A$ iken $y_i = 1$ diğer durumlarda $y_i = 0$ olan bir değişken tanımlayalım

$$\hat{P}(A) = \frac{1}{n} \sum_{i=1}^{n} y_i$$

- (X,Y)'in kovaryansını kestirmek için

$$\hat{C}_n = \frac{1}{n} \sum_{i=1}^{n} x_i y_i$$

Bazı durumlarda, rasgele değişkenin dağılımı bir kaç parametre θ ile tanımlanır, örneğin daha önce gördüğümüz popular dağılımlar gibi

r.v.	Parameters
Bern(p)	$\theta = p$
Geom(p)	$\theta = p$
Binom(n,p)	$\theta = (n,p)$
Poisson(λ)	$\theta = \lambda$
Unif$[a,b]$	$\theta = (a,b)$
Exp(λ)	$\theta = \lambda$
N(μ,σ^2)	$\theta = (\mu,\sigma^2)$

Bu tür parametrik dağılımlar için ilkönce parametrelerini kestirip daha sonra istediğimiz istatistikleri kestirebiliriz For such parametric distributions, we can

En büyük olabilirlik kestirimi

- $X \sim p_X(x;\Theta)$ ve Θ parametresi bilinmiyor olsun.
- Θ'yı kestirmek için $p_X(x;\Theta)$ dağılımından bağımsız ve türdeş üretilmiş eğitim veri kümesi $\{x_i\}_{i=1}^n$ kullanalım.
- En büyük olabilirlik kestiriminde eğitim veri kümesini üreten olabilirliği (likelihood) en büyük yapacak şekilde Θ seçilir.

$$L(\Theta) = p_{X_1,X_2,\dots,X_n}(x_1,x_2,\dots,x_n;\Theta)$$

$$= \prod_{i=1}^{n} p_X(x_i;\Theta)$$

Daha sıklıkla olabilirlik için logaritması en büyüklenir.

$$l(\Theta) = \ln L(\Theta) = \sum_{i=1}^{n} \ln p_X(x_i;\Theta)$$

Ders 10 devamı

Örn: $X \sim Bern(p)$ ve p parametresi bilinmiyor olsun.
p'yi $Bern(p)$ dağılımından bağımsız ve tüdeş olarak üretilmiş eğitim veri kümesi $\{x_i\}_{i=1}^n$ kullanarak EO ile bulalım

$$L(p) = \prod_{i=1}^{n} Bern(p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}$$

$$\ell(p) = \sum_{i=1}^{n} \ln p^{x_i}(1-p)^{1-x_i}$$

$$= \ln p \sum_{i=1}^{n} x_i + \ln(1-p) \sum_{i=1}^{n} (1-x_i)$$

$$= n\bar{x}\ln p + (n - n\bar{x})\ln(1-p)$$

Burada $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$

Olabilirliği en büyük yapan $\hat{p}$'yi bulmak için $\ell(p)$'nin türevini alıp sıfıra eşitleyelim

$$\frac{d\ell(p)}{dp} = \frac{n\bar{x}}{p} - \frac{n - n\bar{x}}{1-p} = 0$$

$$n\bar{x}(1-p) = (n - n\bar{x})p$$

$$\hat{p} = \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Örnek: Gauss parametrelerin EO'si

$X \sim N(\mu, \sigma^2)$ ve $\theta = (\mu, \sigma^2)$ parametreleri bilinmiyor olsun

$$L(\mu,\sigma^2) = \prod_{i=1}^{n} N(\mu,\sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x_i-\mu)^2}{2\sigma^2}}$$

$$\ell(\mu,\sigma^2) = \sum_{i=1}^{n} \ln \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x_i-\mu)^2}{2\sigma^2}}$$

$$= \sum_{i=1}^{n} -\frac{1}{2}\ln 2\pi - \frac{1}{2}\ln\sigma^2 - \frac{(x_i-\mu)^2}{2\sigma^2}$$

$$= -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^2}$$

Olabilirliği en büyük yapan $\hat{\mu}$ ve $\hat{\sigma}^2$'yi bulmak için $\ell(\mu,\sigma^2)$'nin μ ve σ^2'ye göre kısmi türevlerini alıp sıfıra eşitleyelim:

$$\frac{\partial \ell(\mu,\sigma^2)}{\partial \mu} = \sum_{i=1}^{n} \frac{x_i - \mu}{\sigma^2} = 0$$

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$\frac{\partial \ell(\mu,\sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{2\sigma^4} = 0$$

$$\frac{n}{\sigma^2} = \sum_{i=1}^{n} \frac{(x_i-\mu)^2}{\sigma^4} \qquad \sigma^2 = \frac{1}{n}\sum_{i=1}^{n} (x_i - \hat{\mu})^2$$

Rasgele değişkenlerin toplamının ortalaması

$X_1, X_2, \ldots, X_n$ rasgele değişkenlerini toplamı $Y = \sum_{i=1}^{n} X_i$ olsun. Toplamlarının ortalaması aşağıdaki gibidir:

$$E[Y] = E\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} E[X_i]$$

Örnek

Binom rasgele değişkenlerinin ortalaması

$$E[Y] = \sum_{i=1}^{n} E[x_i] = \sum_{i=1}^{n} p = np$$

Örnek ortalaması kestiriminin ortalaması

$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$'dir. Örnek ortalamasının beklentisi

$$E[\bar{X}_n] = E\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} E[X_i]$$

Rasgele değişkenlerin toplamının varyansı

$X_1, X_2, \ldots, X_n$ rasgele değişkenlerin toplamı $Y = \sum_{i=1}^{n} X_i$
Toplamlarının ortalaması aşağıdaki gibidir

$$Var(Y) = E\left[(Y - E[Y])^2\right]$$

$$= \sum_{i=1}^{n} Var(X_i) + \sum_{i=1}^{n}\sum_{j\neq i}^{n} Cov(X_i, X_j)$$

Eğer rasgele değişkenler bağımsızsa tüm $j \neq i$ için $Cov(X_i, X_j) = 0$ olacağından

$$Var(Y) = \sum_{i=1}^{n} Var(X_i)$$

Örnek:

Örnek: Binom rasgele değişekeninin varyansı. $X_1, X_2, \ldots, X_n$ r.d.'leri bağımsız ve türdeş dağılımlı (i.i.d.) $Bern(p)$ olsun. $Y = \sum_{i=1}^{n} X_i$ bir binom r.d.'nidir.

$$Var(Y) = \sum_{i=1}^{n} Var(X_i) = \sum_{i=1}^{n} p(1-p) = np(1-p)$$

Örnek ortalaması kestiriminin varyansı

Bağımsız ve türdeş dağılımlı $X_1, X_2, \ldots, X_n$ rasgele değişkenlerinin örnek ortalaması $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$'dir. Örnek ortalamasının beklentisi:

$$Var(\bar{X}_n) = \frac{1}{n^2}\sum_{i=1}^{n} Var(X_i)$$

$Var(X_i) = Var(X)$, $i = 1, \ldots, n$ olduğundan

$$Var(\bar{X}_n) = \frac{Var(X)}{n}$$

Markov eşitsizliği

$X \geq 0$ rasgele değişkeni pozitif ve sonlu bir ortalaması $E[X]$ olsun. Bu durumda $a > 1$ sayısı için

$$P\{X \geq aE[X]\} \leq \frac{1}{a}$$

Örnek

$X \geq 0$ rasgele değişkeni bir bölgede yaşayan bir insanın yaşı olsun. Bu bölgede yaşayan insanların yaş ortalaması $E[X] = 35$ ise nüfusun ne kadarı 70 ve üzerindedir.
Cevabı tam bilemeyiz ama nüfusundan geriye kalan az 70 yaş ve üzerindedir diyebiliriz $P\{X \geq 70\} \leq \frac{1}{2}$

Örnek

$X \geq 0$ ve $E[X] = 1$ olsun. Markov eşitsizliğine göre

$$P\{X \geq 10\} \leq \frac{1}{10}$$

Şimdi X in bir üstel dağılıma sahip olduğunu kabul edelim $X \sim Exp(1)$ ise $E[X] = 1$ olur. $P\{X \geq 10\}$ olasılığını kesin olarak hesaplayabiliriz.

$$P\{X \geq 10\} = e^{-10} \approx 4{,}53 \cdot 10^{-5} \ll \frac{1}{10}$$

*Buna rağmen X rd hakkında bildiğimiz tek şey ortalaması ise Markov eşitsizliği elde edebileceğine en iyi sınırdır

Chebyshev eşitsizliği

$X \geq 0$ rasgele değişkenin sonlu bir ortalaması $E[X]$ ve varyansı σ_X^2 olsun. Bu durumda $a > 1$ sayısı için:

$$P\{|X - E[X]| \geq a\sigma_X\} \leq \frac{1}{a^2}$$

Örnek: X bir entegre devrenin bir parametresi olsun. X'in ortalaması $E[X]$ ve varyansı σ_X^2 olsun. Parametre X ile ortalaması arasındaki mesafe $3\sigma_X$ veya daha fazla ise entegre devre standard dışı (out-of-spec) oluyor. Entegre devrenin stardart dışı olma olasılığı, $P\{|X - E[X]| \geq 3\sigma_X\}$, nedir?

$$P\{|X - E[X]| \geq 3\sigma_X\} \leq \frac{1}{9}$$

Chebyshev eşitsizliği deçokgeniş bir sınır verebilir

$X \geq 0$, $E[X] = 0$ ve $\sigma_X^2 = 1$ olsun

$$P\{|X| \geq 3\} \leq \frac{1}{9}$$

Şimdi X'in bir Gauss dağılıma sahip olduğunu kabul edelim. $X \sim N(0,1)$ ise $E[X] = 0$ ve $\sigma_X^2 = 1$'dir. $P\{|X| \geq 3\}$ olasılığını kesin olarak hesaplayabiliriz

$$P\{|X| \geq 3\} = P\{X \geq 3\} + P\{X \leq -3\}$$

$$= 2\Phi(-3) = 2(1 - \Phi(3)) \approx 2 \cdot 10^{-3} \ll \frac{1}{9}$$

Buna rağmen X rd hakkında sadece ort ve varyansı biliyorsak chebyshev eşitsizliği elde edebileceğimiz en iyi sınırdır

---

Ders 11

Limit teoremleri

Büyük sayıların zayıf yasası

- Teorem: $X_1, X_2, \ldots, X_n$ bağımsız ve türdeş dağılımlı $E[X]$ ortalamalı ve σ_X^2 varyanslı rasgele değişkenler ve $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ bunların örnek ortalaması olsun. $\epsilon > 0$ sayısı için

$$\lim_{n\to\infty} P\{|\bar{X}_n - E[X]| > \epsilon\} = 0$$

- Bu durumda, $\bar{X}_n$ olasılık olarak $E[X]$'e yakınsar denir.
- Büyük sayıların zayıf yasası şunu söyler: Rasgele değişkenin herhangi bir istatistiğinin $E(g(X))$ örnek ortalaması kestirimi $g(X)$'nin ortalama ve varyansı sonlu ise tutarlıdır.
  - Chebyshev eşitsizliğini kullanarak aşağıdaki eşitsizliği yazabiliriz:

$$P\{|\bar{X}_n - E[\bar{X}_n]| > \epsilon\} \leq \frac{\mathrm{Var}(\bar{X}_n)}{\epsilon^2}$$

  - Daha önce bağımsız ve türdeş dağılımlı r.d.'lerin örnek ortalamasının ortalama ve varyasının aşağıdaki gibi olduğunu bulmuştuk

$$E[\bar{X}_n] = \frac{1}{n}\sum_{i=1}^{n} E[X_i] = E[X]$$

$$\mathrm{Var}(\bar{X}_n) = \frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(X_i) = \frac{\mathrm{Var}(X)}{n}$$

Bövlece

$$P\{|\bar{X}_n - E[X]| > \epsilon\} \leq \frac{\mathrm{Var}(X)}{n\epsilon^2}$$

$n \to \infty$ durumunda büyük sayıların zayıf yasasını ispatlamış oluyoruz.

Güvenirlik aralığı

- $X_1, X_2, \ldots, X_n$ bağımsız ve türdeş dağılımlı $E[X]$ ortalamalı ve σ_X^2 varyanslı rasgele değişkenler ve $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ bunların örnek ortalaması olsun.
- $\epsilon, \delta > 0$ sayıları verildiğinde aşağıdaki eşitsizliği sağlayan örnek sayısı n sayısı ne kadar büyük seçilmelidir?

$$P\{|\bar{X}_n - E[X]| \leq \epsilon\} \geq 1 - \delta$$

- Bir başka deyişle $\bar{X}_n$'nin $[E[X] - \epsilon, E[X] + \epsilon]$ aralığında (interval) $(1-\delta) \geq$ güvenilirliği (confidence) olması için örnek sayısı n sayısı ne kadar büyük seçilmelidir?

Chebyshev eşitsizliği kullanırsak

$$P\{|\bar{X}_n - E[X]| \leq \epsilon\} = 1 - P\{|\bar{X}_n - E[X]| > \epsilon\} \geq 1 - \frac{\mathrm{Var}(\bar{X}_n)}{\epsilon^2} = 1 - \frac{\sigma_X^2}{n\epsilon^2}$$

$\frac{\sigma_X^2}{n\epsilon^2} = \delta$ olarak seçersek $n = \frac{\sigma_X^2}{\delta\epsilon^2}$ elde ederiz.

Örnek:

$\epsilon = 0{,}1\sigma_X$ ve $\delta = 10^{-3}$ olsun. Bu durumda

$$n = \frac{\sigma_X^2}{\delta\epsilon^2} = \frac{\sigma_X^2}{10^{-3} \cdot 0{,}01 \cdot \sigma_X^2} = 10^5$$

10^5 örnek seçilirse $\bar{X}_n, E[X]$'in $\pm 0{,}1\sigma_X$ civarında 0,999 güvenirliği ile kalmasını sağlar.

Güvenirlilik aralığı: Anketör problemi

- p Ali'ye karşı Ayşe'ye oy veren insanların oranı olsun.
- p'yi kestirmek için bir anketör n kişiye ile bağımsız olarak anket yapıyor.
- Anket yapılan i. insan için şöyle bir r.d. tanımlayalım:

$$X_i = \begin{cases} 1, & \text{Ayşe'yi tercih ediyor ise} \\ 0, & \text{Ali'yi tercih ediyor ise} \end{cases}$$

Bu durumda $X_1, X_2, \ldots, X_n$'ler bağımsız ve türdeş dağılımlı Bernoulli r.d.'leri, $Bern(p)$, olurlar.

- Bernoulli r.d.'nin ortalaması p parametresine eşit olduğundan anketör p'yi kestirmek için örnek ortalamasını, $\bar{X}_n$, kullanır.
- $P\{|\bar{X}_n - E[X]| \leq 0.01\} \geq 0.95$ olması için n ne kadar büyük seçilmelidir. Burada $\epsilon = 0.01$ ve $\delta = 0.05$'tir.

$1 - 0{,}95 = 0{,}05$

Chebyshev eşitsizliğini kullanırsak

$$P\{|\bar{X}_n - E[X]| \leq \epsilon\} \geq 1 - \delta = 1 - \frac{\mathrm{Var}(\bar{X}_n)}{\epsilon^2} = 1 - \frac{\sigma_X^2}{n\epsilon^2}$$

- Bernoulli r.d'nin varyansı $\sigma_X^2 = p(1-p)$'dir. p parametresini bilmiyoruz ama p 0 ile 1 arasında olduğundan $\sigma_X^2 = p(1-p) \leq 0{,}25$ olacaktır. (Markov).

Böylece

$$P\{|\bar{X}_n - p| \leq 0{,}01\} \geq 1 - 0{,}05 \geq 1 - \frac{0{,}25}{n(0{,}01)^2}$$

$$0{,}05 = \frac{0{,}25}{n(0{,}01)^2}$$

$$n = \frac{0{,}25}{0{,}05(0{,}01)^2} = 5.10^4$$

Gauss rasgele değişkenlerinin toplamı

Bir Gauss r.d. $X \sim N(\mu, \sigma^2)$ için olkf:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Gauss r.d'lerin bazı kullanışlı özellikleri vardır.

- Eğer $Y = aX + b$ ise $Y \sim N(a\mu + b, a^2\sigma^2)$ olur.
- Eğer $X_1, X_2, \ldots, X_n$ bağımsız ve $X_i \sim N(\mu_i, \sigma_i^2)$ ise $W = \sum_{i=1}^{n} X_i \sim N\left(\sum_{i=1}^{n}\mu_i, \sum_{i=1}^{n}\sigma_i^2\right)$ olur
- Gaussların ağırlıklandırılmış toplamı $W = \sum_{i=1}^{n} a_i X_i$ dahi bir gauss'tur.
- Bağımsız ve türdeş dağılımlı r.d.lerin kendilerin Gauss olmasa bile standart toplamlarının yaklaşık olarak Gauss olduğunu göstereceğiz.
- Bu sonuç merkezi limit teoremi (central limit theorem) olarak bilinmektedir.

Ders 11 devamı

Standart toplam

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \left(\frac{X_i - E[X]}{\sigma_X} \right)$$

(örneklem sayısı; ortalama; varyans)

Z_n standard bir r.d'dir çünkü $E(Z_n)=0$ ve $\sigma_{Z_n}^2 = 1$

- Z_n örnek ortalaması $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ cinsinden aşağıdaki gibi yazılabilir:

Merkez limit teoremi (MLT)

- Teorem: $X_1, X_2, \dots, X_n$ bağımsız ve türdeş dağılımlı sonlu $E[X]$ ortalamalı ve σ_X^2 varyanslı rasgele değişkenler, Z_n bunların standard toplamını ve $F_{Z_n}(z)$, Z_n'nin bdf'si olsun. Bu durumda

$$\lim_{n\to\infty} F_{Z_n}(z) = \Phi(z)$$

- Burada $\Phi(z)$ standard normal (Gauss) r.d.'nin, N(0,1), bdf'sidir.
- Bu durumda şunu söyleyebiliriz Z_n dağılım olarak $Z \sim N(0,1)$'e yakınsar.
- Merkezi limit teoremi neden Gauss dağılımının birçok fiziksel olayda kullanıldığını açıklar. Örneğin, bir direncin üzerindeki ısıl gürültü gerilimi elektronların rasgele hareketinden kaynaklanan milyarlarca küçücük gerilimin toplamından oluşmaktadır. Bu küçük gerilimlerin kendi dağılımlarının ne olduğundan bağımsız olarak gürültü gerilimi Gauss'tur.

Örnek

$\text{Bern}(\frac{1}{2})$ → $p = E[X]$ $\quad \sigma^2 = p(1-p) = 0,25$ $\quad \sigma = 0,5$ (1/2)

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \left(\frac{X_i - E[X]}{\sigma_X} \right)$$

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \left(\frac{X_i - 0,5}{0,5} \right)$$'ni bdf'si $Z \sim N(0,1)$'e yakınsar.

Örnek

$X_1, X_2, \dots, X_n$'ler bağımsız ve türdeş dağılımlı tekdüze r.d'leri, $U[-1,1]$ olsun. Bunların standart toplamı $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \left(\frac{X_i}{\sqrt{1/3}} \right)$'nin bdf'si $Z \sim N(0,1)$'e yakınsar.

MLT ile güvenilirlik aralığı

- $X_1, X_2, \dots, X_n$'ler bağımsız ve türdeş dağılımlı bağımsız ve türdeş dağılımlı sonlu $E[X]$ ortalamalı ve σ_X^2 varyanslı rasgele değişkenler ve $\bar{X}_n$ bunların örnek ortalaması olsun.
- $\epsilon, \delta > 0$ sayıları verildiğinde aşağıdaki eşitsizliği sağlayan örnek sayısı n sayısı ne kadar büyük seçilmelidir?

$$P\{|\bar{X}_n - E[X]| \le \epsilon\} \ge 1 - \delta$$

- MLT kullanarak n'ni kestirelim.

$$P\{|\bar{X}_n - E[X]| \le \epsilon\} = P\left\{\left|\frac{1}{n}\sum_{i=1}^{n}(X_i - E[X])\right| \le \epsilon\right\}$$
$$= P\left\{\left|\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\left(\frac{X_i - E[X]}{\sigma_X}\right)\right| \le \frac{\epsilon\sqrt{n}}{\sigma_X}\right\}$$
$$= P\left\{|Z_n| \le \frac{\epsilon\sqrt{n}}{\sigma_X}\right\} \approx 1 - 2\Phi\left(-\frac{\epsilon\sqrt{n}}{\sigma_X}\right)$$

$$\boxed{\delta = 2\Phi\left(-\frac{\epsilon\sqrt{n}}{\sigma_X}\right)}$$

$$\delta = 2\Phi\left(-\frac{\epsilon\sqrt{n}}{\sigma_X}\right)$$

Buradan n'i çekebilmek için Φ fonksiyonunun tersine ihtiyaç vardır. Bunun için bilgisayar veya tablodaki en yakın değer kullanılabilir.

Örnek: $\epsilon = 0.1\sigma_X$ ve $\delta = 10^{-3}$ olsun. Bu durumda

$$10^{-3} = 2\Phi\left(-\frac{0.01\sigma_X\sqrt{n}}{\sigma_X}\right)$$
$$\frac{10^{-3}}{2} = 1 - \Phi(0.1\sqrt{n})$$
$$\Phi(0.1\sqrt{n}) = 1 - \frac{10^{-3}}{2} = 0.9995$$
$$0.1\sqrt{n} = 3.3$$

$n = 1089$ olarak bulunur.

Bu sayı Chebyshev ile bulduğumuz $n = 10^5$'ten çok küçüktür.

MLT ile güvenilirlik aralığı: Anketör problemi

- p Ali'ye karşı Ayşe'ye oy veren insanların oranı olsun.
- p'yi kestirmek için bir anketör n kişiye ile bağımsız olarak anket yapıyor.
- Anket yapılan i. insan için şöyle bir r.d. tanımlayalım:

$$X_i = \begin{cases} 1, & \text{Ayşe'yi tercih ediyor ise} \\ 0, & \text{Ali'yi tercih ediyor ise} \end{cases}$$

Bu durumda $X_1, X_2, \dots, X_n$'ler bağımsız ve türdeş dağılımlı Bernoulli r.d.'leri, Bern(p), olurlar.

- Bernoulli r.d.'nin ortalaması p parametresine eşit olduğundan anketör p'yi kestirmek için örnek ortalamasını, $\bar{X}_n$, kullanır.
- $P\{|\bar{X}_n - E[X]| \le 0.01\} \ge 0.95$ olması için ($\epsilon = 0.01$ ve $\delta = 0.05$) $n = 5 \times 10^4$ olarak seçilmesi gerektiğini Chebyshev eşitsizliği ile bulmuştuk.
- Şimdi MLT ile bulalım

$$P\{|\bar{X}_n - p| \le 0.01\} = P\left\{\left|\frac{1}{n}\sum_{i=1}^{n}(X_i - E[X])\right| \le 0.01\right\}$$
$$= P\left\{\left|\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\left(\frac{X_i - E[X]}{\sigma_X}\right)\right| \le \frac{0.01\sqrt{n}}{\sigma_X}\right\}$$
$$= P\left\{|Z_n| \le \frac{0.01\sqrt{n}}{\sigma_X}\right\}$$

- Bernoulli r.d.'n.n varyansı $\sigma_X^2 = p(1-p) \le 0.25$ olduğundan

$$P\{|\bar{X}_n - p| \le 0.01\} \ge P\left\{|Z_n| \le \frac{0.01\sqrt{n}}{0.5}\right\} \approx 1 - 2\Phi(-0.02\sqrt{n})$$
$$\delta = 2\Phi(-0.02\sqrt{n})$$
$$0.05 = 2\Phi(-0.02\sqrt{n})$$
$$\Phi(0.02\sqrt{n}) = 1 - \frac{0.05}{2} = 0.975$$
$$0.02\sqrt{n} = 1.96$$

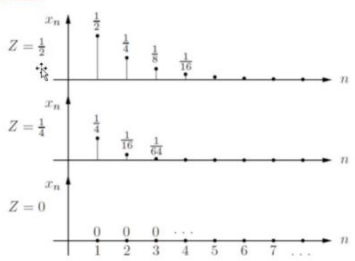
$n = 9604$ olarak bulunur.

Ders 12

Rasgele süreçler

Ayrık zamanlı rasgele süreçler: Örnek

- $X[n] = Z^n, n \ge 1$ ve $Z \sim U[0,1]$ ise $X[n]$ ayrık zamanlı bir süreçtir.
- Örnek diziler:



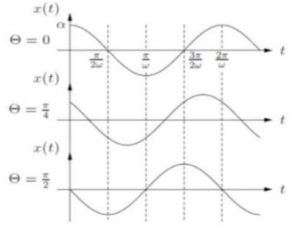
Sürekli zamanlı rasgele süreçler

- Eğer zaman $\mathcal{T}$ sürekli bir küme ise rasgele sürece sürekli zamanlı denir.
- Örnek: Rasgele fazlı sinusoidal işaret

$$X(t) = \alpha\cos(\omega t + \Theta), \qquad t \ge 0$$

Burada $\Theta \sim U[0,2\pi]$ ve α ve ω sabittir.

Örnek fonksiyonlar:



Ortalama ve öz ilişki (otokorelasyon) fonksiyonu

- Ortalama fonksiyonu: $\mu_X(t) = E[X(t)]$, $t \in T$ için
- Öz ilişki / otokorelasyon fonksiyonu:

$$R_X(t_1,t_2) = E[X(t_1)X(t_2)]$$

- Otokovaryans fonksiyonu:

$$C_X(t_1,t_2) = E[(X(t_1) - \mu_X(t_1))(X(t_2) - \mu_X(t_2))]$$
$$\Rightarrow C_X(t_1,t_2) = R_X(t_1,t_2) - \mu_X(t_1)\mu_X(t_2)$$

Örnek: $X(t) = a\cos(\omega t + \Theta)$

$$\mu_X(t) = E(a\cos(\omega t + \Theta)) = \int_0^{2\pi} \frac{a}{2\pi}\cos(\omega t + \theta)\,d\theta = 0$$

($\frac{1}{2\pi}$ → olasılık yoğunluğu)

$$R_X(t_1,t_2) = E(X(t_1)X(t_2))$$
$$= \int_0^{2\pi} \frac{a^2}{2\pi}\cos(\omega t_1 + \Theta)\cos(\omega t_2 + \Theta)\,d\theta$$
$$= \int_0^{2\pi} \frac{a^2}{4\pi}\left[\cos(\omega(t_1+t_2) + 2\Theta) + \cos(\omega(t_1 - t_2))\right]d\theta$$
$$= \frac{a^2}{2}\cos(\omega(t_1 - t_2))$$

Durağan rasgele süreçler

- $X(t_1)$ (veya $X[n]$) rasgele sürecinin ortak olasılık, bdf gibi tüm sonlu dereceden dağılımları zamanla değişmiyorsa tamamen durağan denir. (tamamlanda kesin)
- $X(t)$ (veya $X[n]$) rasgele sürecinin ortalama ve otokorelasyon fonksiyonları zamanla değişmiyorsa geniş anlamda durağandır
- $E[X(t)] = \mu$, zamandan bağımsız
- $R_X(t_1,t_2)$ sadece $\tau = t_2 - t_1$, zaman farkının bir fonksiyonudur.
- $E[(X(t))^2] < \infty$

Birçok durumda tamanlamda durağan ise aynı zamanda geniş anlamda durağandır

Gauss rasgele süreçleri

- $X(t)$ rasgele sürecini tüm $t_1, t_1, \dots, t_k$ ve k değerleri için $X(t_1), X(t_2), \dots, X(t_k)$ rasgele değişkenleri ortak olarak Gauss dağılımına sahipse $X(t)$ bir Gauss rasgele sürecidir (Gaussian random process).
- Bir Gauss rasgele sürecinde ortalama $\mu_X(t)$ ve otokorelasyon $R_X(t_1,t_2)$ fonksiyonunun bilinmesi sürecin istatistiksel olarak tanımlanması için yeterlidir.
- Bir Gauss rasgele sürecinde tam ve geniş anlamda durağanlık aynıdır. Gauss süreci tam anlamda durağan ise aynı zamanda geniş anlamda durağandır. Tersi her zaman doğrudur.

Geniş anlamda durağan sürecin otokelerasyon fonksiyonu

- $X(t)$ geniş anlamda durağan bir süreç olsun. Bu durumda otokelerasyon $R_X(t_1,t_2)$ $R_X(\tau)$ olarak ifade edilir.

1. $R_X(\tau)$ gerçek değerli çift bir fonksiyondur. $R_X(\tau) = R_X(-\tau)$

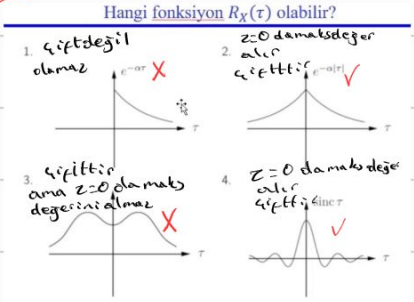
2. $|R_X(\tau)| \le R_X(0) = E[X^2(t)]$, $X(t)$'nin ortalama gücü

3. $T \ne 0$ için $R_X(T) = R_X(0)$ ise $R_X(\tau)$ periyodik ve dalgasıyla $X(t)$ T ile periyodiktir.

Örnek: Rasgele fazlı periyodik olan $X(t) = \alpha\cos(\omega t + \Theta)$ sürecinin otokorelasyon fonksiyonu da periyodiktir $R_X(\tau) = \frac{\alpha^2}{2}\cos(\omega\tau)$.

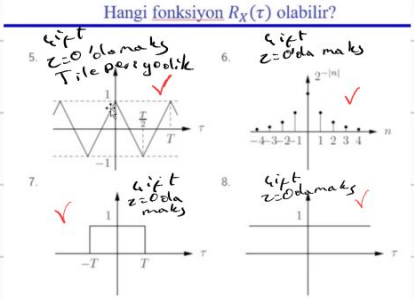
Örnek

Hangi fonksiyon $R_X(\tau)$ olabilir?



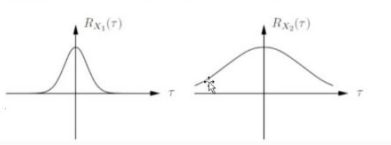
Kaynak: ELM 218 2022-2023 Bahar

Hangi fonksiyon $R_X(\tau)$ olabilir?



Otokorelasyon fonksiyonunun yorumu

- $X(t)$ sıfır ortalamalı geniş anlamda durağan bir süreç olsun. $R_X(\tau)$, τ sabiti ile hemen azalıyorsa örnekler τ'nunartması ile ilişkisizleşiyor demektir. $R_X(\tau)$, τ bağlı olarak yavaşça azalıyorsa örnekler yüksek derecede ilişkilidir.



Ders 12 devamı

Güç spektral yoğunluğu

Geniş anlamda durağan bir rasgele süreç $X(t)$'nin güç spectral yoğunluğu $R_X(\tau)$'nun Fourier dönüşümüdür.

$$S_X(f) = \int_{-\infty}^{\infty} R_X(\tau) e^{-j2\pi f\tau} d\tau$$

Ayrık zamanlı bir sürecin $X[n]$, otokolerasyon fonksiyonu aşağıdaki gibi tanımlanır

$$R_X[k] = E[X[n+k]\,X[n]]$$

ve güç spectral yoğunluğu $R_X[k]$'nın ayrık-zamanlı Fourier dönüşümüdür

$$S_X(e^{j\omega}) = \sum_{k=-\infty}^{\infty} R_X[k] e^{-j\omega k}, \quad -\pi < \omega < \pi$$

ters fourier dönüşümü ise

$$R_X(\tau) = \int_{-\infty}^{\infty} S_X(f) e^{j2\pi f\tau} df$$

$$R_X[k] = \int_{-\pi}^{\pi} S_X(e^{j\omega}) e^{j\omega k} d\omega$$

Özellikleri

1. $S_X(f)$ gerçek ve çift bir fonksiyondur. Gerçek ve çift fonksiyonun Fourier dönüşümü de gerçek ve çift bir fonksiyondur.

2. $\int_{-\infty}^{\infty} S_X(f)df = R_X(0) = E[X^2(t)]$, $X(t)$'nin ortalama gücü. $S_X(f)$ altındaki alan $X(t)$'nin ortalama gücüdür.

3. $S_X(f)$ ortalama güç yoğunluğudur. Örneğin $X(t)$'nin $[f_1, f_2]$ frekans bandındaki ortalama gücü:

$$\int_{-f_2}^{-f_1} S_X(f)df + \int_{f_1}^{f_2} S_X(f)df = 2\int_{f_1}^{f_2} S_X(f)df$$

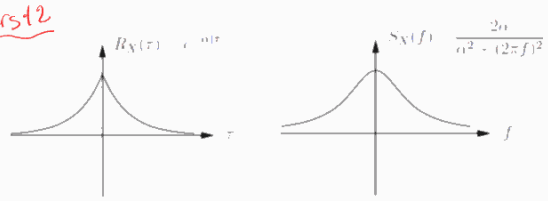
- Her zaman $S_X(f) \geq 0$'dır.
- Genel olarak bir $S(f)$ gerçek, çift, negative olmayan ve

$$\int_{-\infty}^{\infty} S_X(f)df < \infty$$

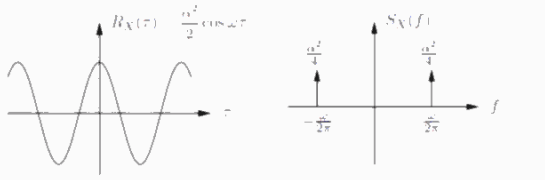
ise bir güç spectral yoğundur. El Gamal

Ders 12

1.



2.



Örnek

$$S_X(f) = \int_{-\infty}^{\infty} e^{-a|\tau|} e^{-j2\pi f\tau} d\tau$$

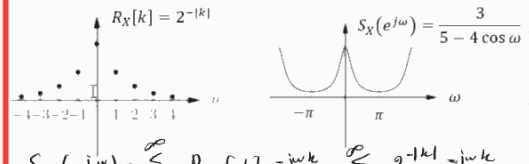
$$= \int_{-\infty}^{0} e^{a\tau} e^{-j2\pi f\tau} d\tau + \int_{0}^{\infty} e^{-a\tau} e^{-j2\pi f\tau} d\tau$$

$$= \int_{-\infty}^{0} e^{(a-j2\pi f)\tau} d\tau + \int_{0}^{\infty} e^{-(a+j2\pi f)\tau} d\tau$$

$$= \frac{1}{(a-j2\pi f)} e^{(a-j2\pi f)\tau}\Big|_{-\infty}^{0} = \frac{1}{(a+j2\pi f)} e^{-(a-j2\pi f)\tau}\Big|_{0}^{\infty}$$

$$= \frac{(1-0)}{a-j2\pi f} - \frac{(0-1)}{(a+j2\pi f)} = \frac{1}{(a-j2\pi f)} + \frac{1}{(a+j2\pi f)}$$

$$S_X(f) = \frac{2a}{a^2+(2\pi f)^2}$$



$$S_X(e^{j\omega}) = \sum_{k=-\infty}^{\infty} R_X[k] e^{-j\omega k} = \sum_{k=-\infty}^{\infty} 2^{-|k|} e^{-j\omega k}$$

$$= \sum_{k=0}^{\infty} \left(\frac{1}{2}\right)^k e^{-j\omega k} + \sum_{k=-\infty}^{-1} \left(\frac{1}{2}\right)^{-k} e^{-j\omega k}$$

İkinci toplamda $m = -k$ dönüşümü yapılır

$$S_X(e^{j\omega}) = \sum_{k=0}^{\infty} \left(\frac{1}{2}e^{-j\omega}\right)^k + \sum_{m=1}^{\infty} \left(\frac{1}{2}e^{j\omega}\right)^m$$

$$= \frac{1}{1-\frac{1}{2}e^{-j\omega}} + \left(\frac{1}{1-\frac{1}{2}e^{j\omega}} - 1\right)$$

$$= \frac{1}{1-\frac{1}{2}e^{-j\omega}} + \left(\frac{1}{1-\frac{1}{2}e^{j\omega}} - 1\right)$$

$$= \frac{1}{1-\frac{1}{2}e^{-j\omega}} + \frac{\frac{1}{2}e^{j\omega}}{1-\frac{1}{2}e^{j\omega}}$$

$$= \frac{1-\frac{1}{2}e^{j\omega} + \left(1-\frac{1}{2}e^{-j\omega}\right)\frac{1}{2}e^{j\omega}}{\left(1-\frac{1}{2}e^{-j\omega}\right)\left(1-\frac{1}{2}e^{j\omega}\right)}$$

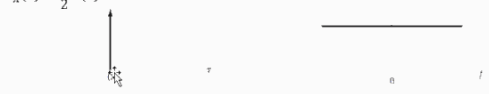
$$= \frac{1-\frac{1}{4}}{1-\cos\omega+\frac{1}{4}} = \frac{3}{5-4\cos\omega}$$

Beyaz gürültü süreci

$$S_W(f) = \frac{N}{2}$$ → Sürecin gücü

$$R_W(\tau) = \frac{N}{2}\delta(\tau)$$

$$R_X(\tau) = \frac{N}{2}\delta(\tau) \qquad S_X(f) = \frac{N}{2}$$



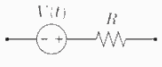
- Beyaz gürültü sürecinde örnekler birbirinden bağımsızdır.
- Sürecin gücü sonsuz olduğundan fiziksel olarak gerçeklenemez. $S_X(f)$'in altında kalan alan sonsuz.
- Ancak rasgele süreçlerde doğrusal sistemlerdeki delta Dirac fonksiyonuna benzer bir rol oynar.
- Isıl gürültü geniş bir band aralığında düz bir güç spectral yoğunluğuna sahip olduğundan beyaz gürültü olarak modellene bilir.

El Gamal

Eğer $X(t)$ beyaz gürültü süreci aynı zamanda Gauss rasgele süreci ise beyaz Gauss gürültü süreci (white Gaussian noise (WGN) process) adını alır.

Isıl gürültü

- R (Ω) direncindeki ısıdan kaynaklı gürültü dirence seri bağlı ve güç spektral yoğunluğu $S_V(f) = 2kTR$ (V^2/Hz) olan bir beyaz Gauss gürültü gerilim kaynağı $V(t)$ olarak modellenir. Burada k Boltzman sabiti ve T Kelvin cinsinden sıcaklıktır.



Ortak olarak geniş anlamda durağan rasgele süreçler

İki geniş anlamda durağan $X(t)$ ve $Y(t)$ rasgele süreçleri eğer çapraz-korelasyon (cross-correlation) fonksiyonları zamanla-değişmiyorsa ortak olarak (jointly) geniş anlamda durağandır denir.

$$R_{XY}(t_1, t_2) = R_{XY}(t_1+\tau, t_2+\tau) = E[X(t_1)\,Y(t_2)]$$

tüm τ'lar için.

Ortak olarak geniş anlamda durağan $X(t)$ ve $Y(t)$ rasgele süreçlerinin çapraz-korelasyon fonksiyonunu $R_{XY}(\tau)$ olarak gösterebiliriz. Burada $\tau = t_1 - t_2$'dir.

$R_{XY}(\tau)$ özelikleri : Çift olması gerekli değildir. X ve Y nin yeri önemlidir.

$$R_{XY}(\tau) = R_{YX}(-\tau)$$

Çapraz-güç spektral yoğunluğu $R_{XY}(\tau)$'nin Fourier dönüşümüdür:

$$S_{XY}(f) = \mathcal{F}\{R_{XY}(\tau)\}$$

Örnek

$X(t) = a\cos(\omega t + \Theta)$ ve $Y(t) = a\sin(\omega t + \Theta)$

$$R_{XY}(t_1, t_2) = E[a^2\cos(\omega t_1 + \Theta)\sin(\omega t_2 + \Theta)]$$

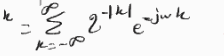
$$= \frac{a^2}{4\pi}\int_0^{2\pi}[\sin(\omega(t_1+t_2) + 2\Theta) - \sin(\omega(t_1-t_2))]d\Theta$$

$$= -\frac{a^2}{2}\sin(\omega(t_1-t_2))$$

Doğrusal zamanla-değişmeyen sistemlerin geniş anlamda durağan süreçlere yanıtı

$h(t)$: birim dürtü yanıtı

$H(f) = \mathcal{F}\{h(t)\}$: frekans yanıtı



Sistemin çıkışı konvolasyon ile bulunur

$$Y(t) = X(t) * h(t) = \int_{-\infty}^{\infty} X(\tau)h(t-\tau)d\tau$$

$$= \int_{-\infty}^{\infty} X(t-\tau)h(\tau)d\tau$$

$$R_{YX}(\tau) = E[Y(\underbrace{t+\tau}_{t_1})X(t)]$$

$$= E\left[\int_{-\infty}^{\infty} h(u)X(t+\tau-u)X(t)du\right]$$

$$= \int_{-\infty}^{\infty} h(u)E[X(t+\tau-u)X(t)]du$$

$$= \int_{-\infty}^{\infty} h(u)R_X(\tau-u)du$$

$$R_{YX}(\tau) = h(\tau) * R_X(\tau)$$

$Y(t)$'nin ortalaması

$$E[Y(t)] = E[X(t)]H(0)$$

$Y(t)$'nin otokorelasyonu :

$$R_Y(\tau) = E[Y(t+\tau)Y(t)]$$
$$= h(-t) * R_{YX}(\tau)$$
$$= h(-t) * h(\tau) * R_X(\tau)$$

$Y(t)$'nin güç spektral yoğunluğu

$$S_Y(f) = \mathcal{F}\{R_Y(\tau)\}$$

$$S_Y(f) = |H(f)|^2 S_X(f)$$