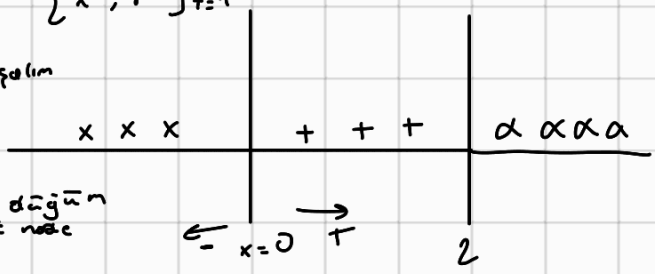
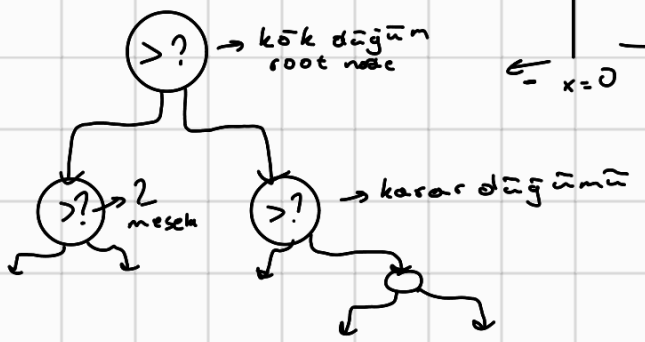
karar ağaçları, Regresyon ağaçları
Decision tree

$\{x^t, r^t\}_{t=1}$

işle yapmaaya çalışalım



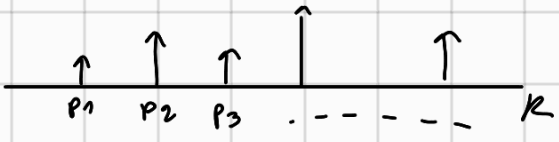


Sınır değeleri nasıl belirleyeceğimizi bulalım

En sonda amaç homojen olarak verileri ayırmak, olabildiğince tek bir sınıf istiyorum

$$p_i = \frac{N_i}{N}$$

Impurity measures:



en saf durum tek bir olasılığın 1 kalanın 0 olması

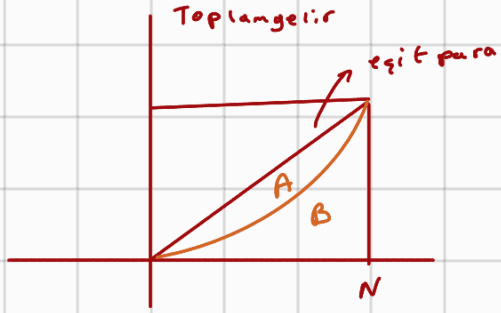
Entropy:

$$I_{entropy} = -\sum_{i=1}^{K} p_i \log p_i$$

→ tek bir sınıf varsa minimum

çok sınıf varsa maximum

Gini Sabiti:



$$\frac{A}{A+B}$$

Bizim uygulamada

$$I_{Gini} = 1 - \sum_{i=1}^{k} p_i^2$$

0 ile $1 - \frac{1}{N^2}$ arasında

dallanırken max entropy nerdeyse ordundevam et

CART

$$\sum_{j=1}^{N} w_j I_j \qquad w_j = \frac{N_j}{N}$$

$$\varepsilon = \varepsilon_k - \varepsilon_{k-1}$$

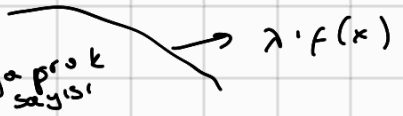
while $\varepsilon > \gamma$ → threshold



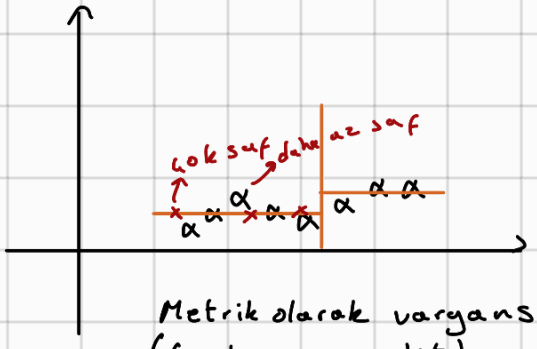
$$d(\theta|X) = \sum_{j=1}^{N} w_j I_j + M \cdot \lambda$$

M → yaprak sayısı, λ → kat sayısı

overfittingi engeller



Regresyon ağaçları



Metrik olarak varyans kaybi ise, vega L1 kullanılabilir.
(Goodness of split)

En büyük sıkıntısı overfitting dalın en alt yaprağına indiğiniz için

L_1 norm aykırı değerlere hassasiyeti az



Ensemble Learning

Bagging

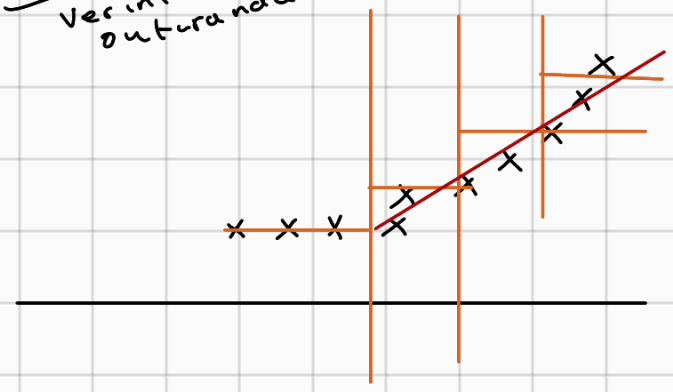


100 tane karar ağacı alırım, yeni bir örnek geldiği zaman oylama yapıyorum böylece kestirimcinin varyansı küçülür.

Random forest

Boosting: Verinin özel bir bölgesine odaklanarak daha iyi bir sınıflandırıcı varsın

bu şekilde yaklaşabilirsin



w_0 → w_0

$w_0 + w_1 x$

Adaboost

$f_i(x), i \in \{0, \ldots, M\}$

$$y = \sum_{i=1}^{m} w_i f_i(x)$$

Aynı modelin parametrelerini değiştirip lineer kombinasyonlarını kullanıyoruz

verinin hangi bölgesinde hangi fonksiyon daha iyi

$$\mathcal{L}(\theta|X) = \sum_{i=1}^{N} w_t(\hat{r}^t - r^t)^2$$

↑ risk gibi

haftaya feature selection
ve dimension reduction işleyeceğiz