Naif Bayes Algoritması Kullanılarak Spam mail tespiti

Fouad Aladhami
f.aladhami2021@gtu.edu.tr
Elektronik Mühendisliği Bölümü, GTÜ, Kocaeli, Türkiye

I. GİRİŞ

Spam e-posta tespiti, dijital iletişimde verimliliği ve güvenliği sağlamak için kritik bir problemdir. Artan dijitalleşmeyle birlikte, kullanıcıları istenmeyen ve zararlı içeriklerden koruma gerekliliği spam tespit algoritmalarının önemini artırmıştır. Günümüzde spam tespiti için kullanılan yaygın yöntemler; karar ağaçları, destek vektör makineleri (SVM), yapay sinir ağları (ANN) ve Naive Bayes algoritması gibi makine öğrenme tekniklerine dayanmaktadır [1].

Bu çalışmada, spam e-posta tespiti için Naive Bayes algoritmasına dayalı bir sınıflandırıcı geliştirilmiş ve bu algoritmanın başarımı belirli bir veri seti üzerinde çeşitli performans metrikleri ile değerlendirilmiştir. Elde edilen sonuçlar, Naive Bayes algoritmasının spam tespitindeki etkinliğini analiz etmek ve diğer yöntemlerle karşılaştırmak amacıyla detaylandırılmıştır.

II. VERİ SETİ VE VERİ İŞLEME

Kullanılan veri seti, spam ve ham e-postaların metin içeriklerini ve sınıflandırma etiketlerini içermektedir. Veri seti tam olarak 5171 tane e-posta içermektedir ve her e-postanın spam olup olmadığı belirtilmiştir. Veri seti Kaggle platformu üzerinden alınmıştır. Veri setinin yüzde %67 'si eğitim için %33 test için kullanılmıştır. Her mesaj için tokenization işlemi yapılmıştır, mesajlarda olan noktalama işaretleri ve alfabetik olmayan ifadeler silinmiştir, ayrıca tüm kelimeler küçük harfe çevrilmiştir.

III. NAIF BAYES SINIFLANDIRICISI

Naif Bayes sınıflandırıcı, Bayes teoremine dayalı bir modeldir. Bir e-postanın spam veya ham sınıfına ait olma olasılığı, metin içerisindeki kelimelerin sınıfa ait olma olasılıklarıyla hesaplanır. Bu sınıflandırıcı, özelliklerin bağımsız olduğunu varsayar; bu nedenle "naif" olarak adlandırılır.

A. Bayes Teoremi

Veri Bayes teoremi, gözlemlenen bir veri kümesine dayanarak bir olayın olasılığını hesaplamamızı sağlar. Matematiksel olarak Bayes teoremi denklem (1)'deki gibi gösterilebilir [2].

$$P(C \mid x_1, x_2, \dots, x_N) = \frac{P(x_1, x_2, \dots, x_N|C) \cdot P(C)}{P(x_1, x_2, \dots, x_N \mid C)} \quad (1)$$

Bu formülde:

- $P(C \mid x_1, x_2, \dots, x_N)$: $x_1, x_2, \dots, x_N$ özellik vektörü verildiğinde C sınıfına ait olma olasılığı.
- $P(x_1, x_2, \dots, x_N \mid C)$: C sınıfına ait verilerin $x_1, x_2, \dots, x_N$ özelliklerine sahip olma olasılığı.
- $P(C)$: C sınıfına ait olma olasılığı (sınıfın önsel olasılığı).
- $P(x_1, x_2, \dots, x_N)$: $x_1, x_2, \dots, x_N$ özelliklerinin toplam olasılığı.

İncelen problemde $x_1, x_2, \dots, x_N$ kelime vektörünü temsil etmektedir, sınıflar ise spam veya ham olabilmektedir. Maildeki kelimelere bakılarak mailin sapam veya ham olup olmadığını tespit edilebilmeyi çalışılmaktadır. Malin spam olması için denklem 2 de verilen oran 1'den büyük olmalıdır.

$$\frac{P(spam|x_1, x_2, \dots, x_N)}{P(ham|x_1, x_2, \dots, x_N)} \geq ? \, 1 \quad (2)$$

Denklem 2'deki $P(spam|x_1, x_2, \dots, x_N)$, $x_1, x_2, \dots, x_N$ kelime vektörü verilmişken mailin spam olma olasılığını göstermektedir, $P(ham|x_1, x_2, \dots, x_N)$ ise $x_1, x_2, \dots, x_N$ kelime vektörü verilmişken mailin ham olma olasılığını temsil etmektedir. Bu iki olasılık bilinmemektedir. Denklem 1'i kullanarak bu denklemi, denklem 3'teki gibi güncellenebilir.

$$\frac{P(x_1, x_2, \dots, x_N| \, spam).P(spam)}{P(x_1, x_2, \dots, x_N| \, ham).P(ham)} \geq ? \, 1 \quad (3)$$

Denklem 3'teki $P(spam)$ veri setindeki spam gelme olasılığını, $P(ham)$ ise veri setindeki ham gelme olasılığını temsil etmektedir.

B. Naif varsayımı

Naif Bayes sınıflandırıcı, özelliklerin bağımsız olduğunu varsayar. Yani, bir mesajdaki her bir kelimenin diğer kelimelerden bağımsız olduğunu kabul ederiz. Bu durumda, $P(x_1, x_2, \dots, x_N \mid C)$ denklem 4'te gösterildiği şekilde hesaplanabilmektedir.

$$P(x_1, x_2, \dots, x_N \mid C) = \prod_{i=1}^{N} P(x_i \mid C) \quad (4)$$

Burada x_i, mesajdaki her bir kelimeyi temsil etmektedir. Bu varsayımı kullanarak denklem 3 güncellenebilir ve denklem 5 teki gibi yazılabilir.

$$\frac{[\prod_{i=1}^{N} P(x_i \mid \text{spam})] \,.\, P(spam)}{[\prod_{i=1}^{N} P(x_i \mid \text{ham})] \,.\, P(ham)} \geq ? \, 1 \quad (5)$$

Bu denklemdeki $P(x_i \mid \text{spam})$ ve $P(x_i \mid \text{ham})$ olasılıklarını veri setindeki tüm spam ve ham mesajların içerdiği kelime sayılarının kullanılmasıyla hesaplanabilmektedir.

IV. PERFORMANS DEĞERLENDİRME METRİKLERİ

Sınıflandırıcı performansını değerlendirmek için accuracy (doğruluk), precision (kesinlik), recall (duyarlıık) ve F1-score (F1 skoru) metrikleri kullanılmıştır. Böylece bu çalışma kapsamında geliştirilen modelin doğruluğu çeşitli yöntemlerle değerlendirilmiştir [3].

A. Doğruluk (Accuracy)

Doğruluk, tüm doğru sınıflandırmaların toplam veri setine oranıdır. Denklem 6'da denklemi gösterilmiştir

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6)$$

Burada:

- TP (True Positive): Gerçekten spam olan ve doğru bir şekilde spam olarak sınıflandırılan örnekler.
- TN (True Negative): Gerçekten ham olan ve doğru bir şekilde ham olarak sınıflandırılan örnekler.
- FP (False Positive): Gerçekten ham olup yanlışlıkla spam olarak sınıflandırılan örnekler.
- FN (False Negative): Gerçekten spam olup yanlışıkla ham olarak sınıflandırılan örnekler.

B. Kesinlik (Precision)

Kesinlik, bu problemde spam olarak sınıflandırılan tüm e-postalar arasında gerçekte spam olanların oranını ifade eder. Bu metrik, özellikle yanlış pozitiflerin etkisini azaltmak için kullanılmaktadır ve denklem 7 de nasıl hesaplanacağı gösterilmektedir.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (7)$$

C. Duayarlılık (Recall)

Duyarlılık, bu problemde gerçekte spam olan e-postaların ne kadarının doğru bir şekilde spam olarak tespit edildiğini gösterir. Spam e-postaların doğru sınıflandırılmasını ölçmek için uygundur. Formülü denklem 8' de gösterilmişitr.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (8)$$

D. F1 Skoru (F1 Score)

F1 skoru, duyarlılık ve kesinliğin harmonik ortalamasıdır. Hem yanlış pozitiflerin hem de yanlış negatiflerin etkisini azaltmak için kullanılır ve denklem 9 da gösterilmiştir.

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (9)$$

V. SONUÇLAR

Bu çalışmada geliştirilen modelin doğruluk, keskinlik, duyarlılık ve F1 skoru Tablo-1'de verilmiştir. Test seti üzerindeki doğruluk 0.84, F1 skoru 0.64 çıkmıştır. Bu modelin performansını geliştirmek için veri setinin büyüklüğü attırılabilir ve tokenization işlemi geliştirelebilir.

Değerlendirme Metriği	**Eğitim seti üzerindeki değeri**	**Test seti üzerindeki değeri**
Accuracy	0.94226	0.84241
Precision	0.99252	0.96862
Recall	0.80423	0.48622
F1 score	0.88851	0.64744

Tablo 1

KAYNAKÇA

[1] S. K. Trivedi, "A study of machine learning classifiers for spam detection", içinde *2016 4th International Symposium on Computational and Business Intelligence (ISCBI)*, Eyl. 2016, ss. 176-180. doi: 10.1109/ISCBI.2016.7743279.

[2] H. Gao, "Spam Sorting Based on Naive Bayes Algorithm", içinde *2023 International Conference on Blockchain Technology and Applications (ICBTA)*, Ağu. 2023, ss. 81-84. doi: 10.1109/ICBTA60381.2023.00023.

[3] J. Mythili, B. Deebeshkumar, T. Eshwaramoorthy, ve J. N. Ajay, "Enhancing Email Spam Detection with Temporal Naive Bayes Classifier", içinde *2024 International Conference on Communication, Computing and Internet of Things (IC3IoT)*, Nis. 2024, ss. 1-6. doi: 10.1109/IC3IoT60841.2024.10550229.