Karar ağacı alogoritması ile sınıflandırma

Fouad Aladhami
f.aladhami2021@gtu.edu.tr
Elektronik Mühendisliği Bölümü, GTÜ, Kocaeli, Türkiye

I. GİRİŞ

Karar ağaçları, sınıflandırma ve regresyon problemlerinde yaygın olarak kullanılan bir makine öğrenmesi algoritmasıdır. Karar ağaçları, veriyi ayrıştırarak her bir yaprak düğümünde nihai sınıf veya tahmin edilen değeri temsil eder.

Bu çalışmada, sınıflandırma problemlerinde yaygın olarak kullanılan Karar Ağaçları (Decision Trees) algoritması geliştirilmiş ve uygulanmıştır. Entropi ve Gini İndeksi gibi saflaştırma ölçütleri kullanılarak veri setinde en iyi ayrımı sağlayan özellik ve eşik değerleri belirlenmiştir. Önerilen algoritma, derinlik sınırı baz alınarak geliştirilmiş ve grafiksel olarak görselleştirilmiştir.

II. KULLANILAN KARAR AĞACININ YAPISI

Bir karar ağacı, kök düğümden başlayarak özellikleri ve eşik değerleri üzerinden veriyi dallara ayıran bir modeldir. Her bir iç düğüm bir özellik (feature) ve eşik değer (threshold) içerir. O özelliğin değerine bakarak eğer büyükse başka bir düğüme, küçükse başka bir düğüme aktarmaktadır ve böylece bir ağaç oluşmaktadır. Yaprak düğümler (yani ağacının son düğümleri) ise sınıf etiketlerini veya tahmin edilen değerleri temsil eder.

III. SAFLIK ÖLÇÜTLERİ

Karar ağaçlarının performansını değerlendirmek ve hatayı minimize etmek için saflık ölçütleri kullanılır. Bu çalışmada Entropi [1] ve Gini indexi'ne [2] değinilmiştir, model için Gini indexi kullanılmıştır.

A. Entropi

Entropi, verinin saflığını ölçmek için kullanılır ve daha düşük entropi daha saf bir veri setini ifade eder. Matematiksel olarak Entropi denklem (1)'deki gibi gösterilebilir.

$$H(y) = -\sum_{i=1}^{C} p_i \log(p_i) \tag{1}$$

Burada C sınıf sayısını temsil ederken p_i ise i sınıfın olasılığını temsil etmektedir.

B. Gini indexi

Gini İndeksi de benzer şekilde verinin saflığını ölçmek için kullanılır, ancak daha hızlı hesaplanabilirliği nedeniyle pratikte daha yaygındır. Gini indexi denklem 2'de verilmiştir.

$$G(y) = 1 - \sum_{i=1}^{C} p_i^2 \tag{2}$$

IV. KARAR AĞACININ OLUŞTURULMASI VE KULLANILAN ALGOİTMA

II'de anlatılan ağaç yapısını kurabilmek için en veri hangi özelliğin hangi eşik değerine göre en iyi bölündüğünü bulmak gereklidir, bunun için saflık ölçütleri kullanılmaktadır. Ve aşağıdaki adımlar izlenmektedir.[3]

A. Veri Bölme (Splitting)

Veri, belirli bir özellik ve eşik değeri üzerinden iki alt gruba bölünür. Veri bölme işlemi şu şekilde gerçekleştirilir. X Veriyi ve y ise etiket değerlerini temsil etsin, belirli bir i özelliği ve t eşik değeri için dallar denklem 3'te göründüğü gibi gösterilebilir.

$$\begin{aligned} Sol\ Dal &= \{(X_j, y_i) |\ X_{j,i} \le t\} \\ Sağ\ Dal &= \{(X_j, y_i) |\ X_{j,i} > t\} \end{aligned} \tag{3}$$

B. En iyi bölme kriteri (Best split criteria)

En iyi bölmeyi bulmak, karar ağacı algoritmasının en kritik adımlarından biridir. Ağaç, veriyi bölerek bilgi kazancını maksimize etmeye çalışır. Bu işlemde, her bir özellik (feature) ve olası eşik değerleri (thresholds) test edilerek en iyi bölme noktası seçilmektedir. Bunun için aşağıdaki adımlar izlenmektedir.

1- Özellikler Üzerinde Dolaşma

Tüm özellikler $\{1,2,\dots,m\}$ sırasıyla ele alınır ve her bir özellik için potansiyel eşik değerleri belirlenir.

2- Eşik değerlerinin belirlenmesi

Belirli bir özellik için, veri kümesindeki benzersiz değerler (unique values) elde edilir ve bu değerler sıralanır. Bu sıralı eşik değerleri, veri kümesini bölebileceğimiz potansiyel noktalardır.

3- Veriyi bölme

Seçilen özellik ve eşik değeri için veri kümesi iki alt kümeye ayrılır:

- X_{left} : Seçilen özellik değeri eşik değerinden küçük olan örnekler.
- X_{right} : Seçilen özellik değeri eşik değerine eşit veya büyük olan örnekler.

4- Alt Kümlerin Gini Katsayısının Hesaplanması

Ayrılan iki alt kümenin de Gini katsayıları $G(y_{\text{left}})$ ve $G(y_{\text{right}})$ olmak üzere hesaplanır.

5- Ağırlıklı Gini katsayısının hesaplanması

Alt kümelerin büyüklüklerine göre ağırlıklı toplam Gini katsayısı şu şekilde hesaplanır:

$$G_{\text{weighted}} = \frac{n_{y_{\text{left}}}}{n} \times G(y_{\text{left}}) + \frac{n_{y_{\text{right}}}}{n} \times G(y_{\text{right}})$$

Burada:

- $n_{y_{\text{left}}}$: Sol alt kümenin boyutu
- $n_{y_{\text{right}}}$: Sağ alt kümenin boyutu
- n : Toplam örnek sayısı.

Ağırlıklı Gini katsayısı, bölmenin genel homojenliğini ölçer. Küçük bir değer çıkması, daha homojen bir bölme olduğunu gösterir.

6- En iyi özellik ve eşiğinin seçilmesi

Her özellik ve eşik değeri için hesaplanan ağırlıklı gini katsayısı karşılaştırılır ve en düşük gini katsayısına sahip özellik ve eşik değeri en iyi bölme noktası olarak seçilir.

Ağaç rekürsif olarak belirli bir değere ulaşana veya veri tamamen saflaşana kadar inşa edilir. Her düğüm için en iyi bölme bulunur ve veri bölünür. Bu işlem belirlenen maksimum derinlik sağlanana kadar tekrarlanabilmektedir.

V. TAHMININ YAPILMA YÖNTEMI

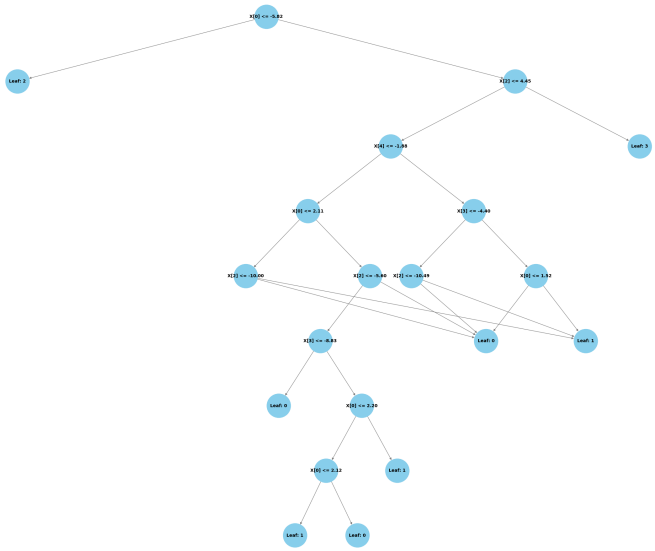
Bir Örnek verinin hangi sınıfa ait olduğunu belirlemek için ağaç kökünden başlanarak uygun dallar üzerinden ilerlenir, yaprak düğüme gelince ise onun değeri tahmin olarak döndürülür.

VI. PERFORMANS DEĞERLENDİRME VE SONUÇ

Oluşturulan karar ağacı algoritması denenmesi için, karar ağacı X_train ve y_train den oluşan bir veri seti ile oluşturuldu. Burada X_train 5 boyutludur yani 5 tane özellik sütününe sahiptir. Oluşturulan model X_test ve y_test adlı test verisi ile değerlendirilmiştir.

A. Oluşan karar ağacının görüntülenmesi

X_train ve y_train kullanılarak oluşturulan karar ağacı şekil 1'de görselleştirilerek oluşturulmuştur.



Şekil 1: Eğitim verileri kullanılarak oluşturulan karar ağacının görselleştirilmiş gösterimi

Yapılan modelin doğruluğu (accuracy), Scikit-learn'de olan DecisionTreeClassifier fonksiyonu kullanarak aynı verilerle oluşturulmuş modelle karşılaştırılmıştır ve sonuçlar Tablo1'de verilmiştir. Doğruluk oranları yaklaşık aynı çıkmış olup bu çalışmada yapılan modelin doğruluğunu göstermektedir.

Değerlendirme Metriği	**Çalışmada bahsedilen yöntemle oluşturulan model**	**Scikit-learn kullanılarak oluşturulan model**
Accuracy	0.997	0.998

Tablo 1

KAYNAKÇA

[1] F.-J. Yang, "An Extended Idea about Decision Trees", içinde *2019 International Conference on Computational Science and Computational Intelligence (CSCI)*, Ara. 2019, ss. 349-354. doi: 10.1109/CSCI49370.2019.00068.

[2] H. Liu, M. Zhou, X. S. Lu, ve C. Yao, "Weighted Gini index feature selection method for imbalanced data", içinde *2018 IEEE 15th International Conference on Networking, Sensing and Control (ICNSC)*, Mar. 2018, ss. 1-6. doi: 10.1109/ICNSC.2018.8361371.

[3] J. R. Quinlan, "Induction of decision trees", *Mach Learn*, c. 1, sy 1, ss. 81-106, Mar. 1986, doi: 10.1007/BF00116251.