Hiperspektral Görüntü için PCA ile Boyut Azaltılması ve K-means ile Kümeleme

Fouad Aladhami
f.aladhami2021@gtu.edu.tr
Elektronik Mühendisliği Bölümü, GTÜ, Kocaeli, Türkiye

I. GİRİŞ

Bu çalışmada, hiperspektral bir görüntü olan Salinas görüntüsü üzerinde boyut azaltma ve kümeleme işlemleri gerçekleştirilmiştir. Boyut azaltma için Temel Bileşen Analizi (Principal Component Analysis - PCA) yöntemi, kümeleme için ise K-means algoritması uygulanmıştır.

Amaç, PCA ile veri boyutunu azaltarak kümeleme işleminin performansını iyileştirmek ve sonuçları Salinas_gt dosyasında bulunan yerleşik sınıf etiketleriyle karşılaştırmaktır.

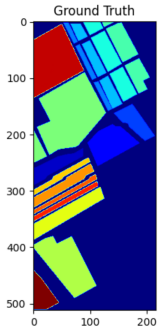
II. VERİ YAPISI

Bu çalışmada iki görüntü kullanılmaktadır.

- **Salinas.mat**: 3 boyutlu bir hiperspektral görüntü verisi. Her piksel bir spektral bant vektörünü temsil eder. Ve denklem (1'deki gibi ifade edilebilir.

$$data.shape = n_{rows}, n_{cols}, n_{bands} = 512, 217, 224 \quad (1)$$

- **Salinas_gt.mat**: Her piksel için sınıf etiketlerini içeren 2 boyutlu bir zemin doğruluk (ground truth) haritası. Şekil 1'de gösterilmiştir.



Şekil 1: Zemin doğruluk (ground truth) haritası

III. PCA İLE BOYUT AZALTMA

PCA, çok boyutlu bir veriyi daha düşük boyutlu bir uzaya projelendiren bir boyut azaltma yöntemidir.

A. PCA'nın adımları

İlk olarak veri standardizasyonu için verinin ortalaması alınır ve her bir özellik sıfır ortalama olacak şekilde standartlaştırılır. Standardizasyon işlemi denklem (2)'de gösterilmiştir. Burada x özellikleri, μ ise özelliklerin ortalamasını ifade etmektedir.

$$x_{std} = x - \mu \quad (2)$$

Sonrasında ise kovaryans matrisi hesaplanmaktadır[1]. Kovaryans matrisi, her bir özellik çiftinin ilişkisinin derecesini ölçer. Ve denklem (3)'teki gibi ifade edilebilir.

$$\Sigma = \frac{1}{n-1} X^T X \quad (3)$$

Sonrasında ise kovaryans matrisinin özdeğerleri ve özvektörleri denklem (4)'teki gibi hesaplanır.

$$\Sigma v = \lambda v \quad (4)$$

Burda λ, özdeğer; v, özvektördür. Sonrasında ise Özdeğerler azalan sırada sıralanır ve ilk k özvektör seçilir.

Özvektörler bulunduktan sonra orijinal veri, seçilen özvektörlere denklem (5)'teki gibi projelendirilir.

$$X_{reduced} = X_{std} V_k \quad (5)$$

IV. K-MEANS ALGORİTMASI

K-means, veriyi K adet küme merkezine atayan bir kümeleme algoritmasıdır. Bu algoritma başlangıçta rastgele seçilen K küme merkezi ile başlar. Her bir veri noktası, en yakın küme merkezine atanır. Bu atama işlemi, Öklid uzaklığı kullanılarak yapılır ve denklem 6'daki gibi ifade edilebilir.

$$label(x_i) = \text{argmin}_j \parallel x_i - c_j \parallel \quad (6)$$

Burada x_i, bir veri noktası; c_j, j-inci küme merkezidir. Veri noktaları kümelere atandıktan sonra, her bir küme için yeni merkezler hesaplanır. Yeni merkezler, o kümedeki veri noktalarının ortalaması olarak denklem 7'deki gibi güncellenir.

$$c_j = \frac{1}{S_j} \sum_{x_i \in S_j} x_i \quad (7)$$

Burada S_j, j-inci kümeyi; c_j, o kümenin yeni merkezini ifade eder. Algoritmanın temel amacı, denklem 8 'de verilen toplam hata fonksiyonunu minimize etmektir [2].

$$J = \sum_{j=1}^{k} \sum_{x_i \in S_j} \|x_i - c_j\|^2 \quad (8)$$

Hata fonksiyonu belirli bir eşik değerine ulaşıncaya kadar veya maksimum iterasyon sayısına kadar işlem tekrarlanır. Kodda K-means algoritması manuel olarak numpy kullanılarak yazılmış ve küme sayısı, ground truth sınıf sayısına (k) eşitlenmiştir.

V. ADJUST RAND INDEX (ARI) METRİĞİ

Adjusted Rand Index (ARI), bir kümeleme algoritmasının sonuçlarını doğru sınıf etiketleriyle karşılaştırarak değerlendirir ve rastgele tahminlerin etkisini düzeltir[3]. ARI, -1 ile 1 arasında değer alır:

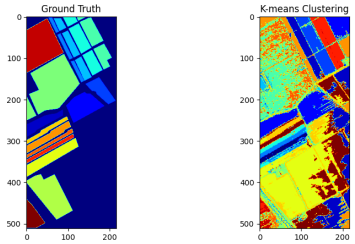
- 1: Mükemmel uyum.
- 0: Rastgele tahminle eşdeğer.
- Negatif: Beklentinin altında bir sonuç.

ARI'nin avantajı, kümelerin etiket sırasından etkilenmemesi ve rastgele tahminlerin sonuç üzerindeki etkisini ortadan kaldırmasıdır. Bu çalışma kapsamında, K-means algoritmasının çıktılarının ground truth ile ne kadar uyumlu olduğunu ölçmek için ARI kullanıldı.

VI. UYGULAMA

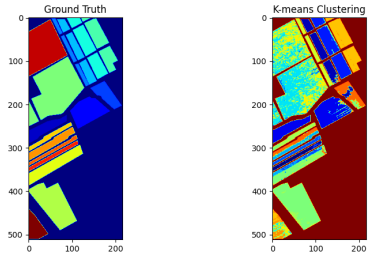
PCA veya K-means gibi algoritmalar, girdinin satırlarının veri örneklerini (pikselleri) ve sütunlarının ise özellikleri (spektral bantlar) ifade ettiği bir format bekler. Bu yüzden veriyi $n_{pixels} \times n_{bands}$ boyutuna indirgemek, işlemleri sadeleştirir. Çıkan veri $data_{reshaped}$ olarak adlandırılmıştır. Ve boyutu $n_{pixels}, n_{bands} = 111104, 224$ şeklindedir. Bu veri PCA algoritmasına girdi olarak verilmektedir ve boyut azaltmada kullanılmaktadır. Sonra ise K-means ile sınıflandırılma yapılmıştır. Farklı $n_{components}$ değerleri için ise PCA ile boyut indirgeme yapılmış ve sonuçlar incelenmiştir. Boyut indirgeme sayesinde kümeleme daha hızlı yapılabilmektedir.

$n_{components}$=50 için PCA ile boyut indirgeme yapılıp sonra ise K-means ile sınıflandırılma yapıldığında oluşan görüntü Şekil 2'teki gibidir.



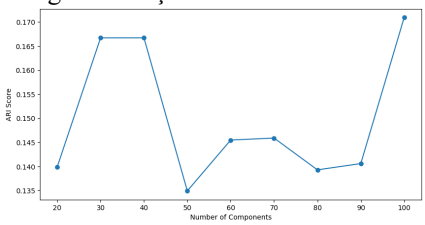
Şekil 2: n_components=50 için ground truth ve K-means sonucu

Daha iyi görünmesi için arka zemin olan yeri kaldırıp (ground truth görüntüsündeki sıfıra denk gelen yer) tekrar çizdirilirse Şekil 3'teki görüntü elde edilir.

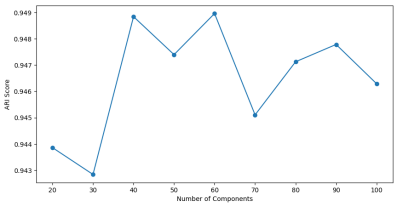


Şekil 3:n_components=50 için ground truth ve K-means sonucu (arka plan kaldırılmıştır)

Her iki durum için $n_{components}$ değeri 20'dan 100'e 10 adımlarla arttıralarak ARI skoru çizdirilirmiştir, Şekil 4'te ve Şekil 5'te gösterilmiştir.



Şekil 4: ARI skoru farklı n_component değerleri için (arka plan dahil olan görüntüler arasında)



Şekil 5:ARI skoru farklı n_component değerleri için (arka plan dahil olamyan görüntüler arasında)

KAYNAKÇA

[1] S. Ranjan, D. R. Nayak, K. S. Kumar, R. Dash, ve B. Majhi, "Hyperspectral image classification: A k-means clustering based approach", içinde *2017 4th International Conference on Advanced Computing and Communication Systems (ICACCS)*, Oca. 2017, ss. 1-7. doi: 10.1109/ICACCS.2017.8014707.

[2] V. K. Dehariya, S. K. Shrivastava, ve R. C. Jain, "Clustering of Image Data Set Using K-Means and Fuzzy K-Means Algorithms", içinde *2010 International Conference on Computational Intelligence and Communication Networks*, Kas. 2010, ss. 386-391. doi: 10.1109/CICN.2010.80.

[3] R. R. de de Vargas ve B. R. C. Bedregal, "A Way to Obtain the Quality of a Partition by Adjusted Rand Index", içinde *2013 2nd Workshop-School on Theoretical Computer Science*, Eki. 2013, ss. 67-71. doi: 10.1109/WEIT.2013.33.