Perceptron Kullanarak Regresyon

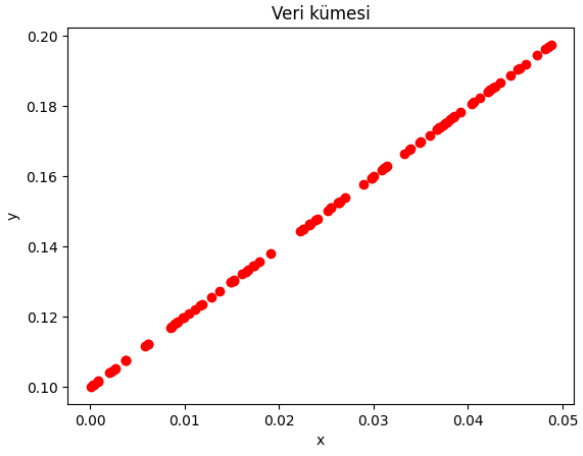
Fouad Aladhami
f.aladhami2021@gtu.edu.tr
Elektronik Mühendisliği Bölümü, GTÜ, Kocaeli, Türkiye

I. GİRİŞ

Bu çalışmada, veri seti üzerinde bir tek katmanlı algılayıcı (perceptron) kullanılarak regresyon modeli oluşturulmuş ve modelin parametreleri sigmoid aktivasyon fonksiyonu kullanılarak optimize edilmiştir. Eğitim sürecinde doğrusal kombinasyon, sigmoid aktivasyonu ve kayıp fonksiyonu (Ortalama Kare Hatası) dikkate alınarak ileri ve geri yayılım algoritması uygulanmıştır. Model performansı, tahmin değerleri ve gerçek değerler karşılaştırılarak görselleştirilmiştir.

II. VERİ SETİ

Veri seti data.npy dosyasından okunmuştur. Giriş (x) ve çıktı (y) olmak üzere veriler Şekil 1'de gösterilmiştir.



Şekil 1: Dosyadan okunan veriler

III. PERCEPTRON YAPISI VE PARAMETRELERİN ÖĞRENİLMESİ

Model, tek bir katmandan oluşan ve sigmoid aktivasyon fonksiyonu kullanan bir algılayıcı olarak tanımlanmıştır.

A. Perceptron ve sigmoid

Model, x giriş verisi, w ağırlık matrisi, b bias değeri, olduğunda perceptron dan sonraki veri olan z yani doğrusal kombinasyonun sonucu denklem 1'de ki gibi ifade edilebilir [1].

$$z = x \cdot w + b \tag{1}$$

Tahminler ($\hat{y}$) ise sigmoid aktivasyon fonksiyonuyla ($\sigma(z)$) ile modellenmiştir ve denklem 2'de gösterilmiştir [2].

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \tag{2}$$

B. Kayıp fonksiyonu

Modelin performansı MSE (Mean squared error) kayıp fonksiyonu ile değerlendirilmiştir. Kayıp fonksiyonu denklem 3'te ki gibi ifade edilebilir.

$$L = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2 \tag{3}$$

Denklem 3'te, L ortalama kare hatası, N veri örneği sayısı, y_i gerçek değerler ve $\hat{y}_i$ tahmin edilen değerleri temsil etmektedir.

C. İleri ve geri yayılım

İleri yayılım, modelin bir tahmin yapması için kullanılan süreçtir. Denklem 1 ve Denklem 2'yi birleştirerek denklem 4'te ki gibi ifade edilebilir.

$$\text{İleri Yayılım: } \hat{y} = \sigma(x \cdot w + b) = \sigma(z) \tag{4}$$

Geri yayılımda ise ağırlık ve bias değerleri, denklem 3'te verilmiş kayıp fonksiyonunun gradyanları ile güncellenir. Kayıp fonksiyonun w ve b 'ye görev türevini bulmak için zincir kuralından yararlanılmıştır ve denklem 5 ve 6'da gösterilmiştir.

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w} \tag{5}$$

$$\frac{\partial L}{\partial b} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial b} \tag{6}$$

Ve $\frac{\partial \hat{y}}{\partial z}$ sigomoidin türevinden denklem 7'deki gibi bulunabilir.

$$\frac{\partial \hat{y}}{\partial z} = \sigma'(z) = \sigma(z) \cdot (1 - \sigma(z)) \tag{7}$$

$\frac{\partial z}{\partial w}$ ve $\frac{\partial z}{\partial b}$ ise denklem 8'deki gibi elde edilebilir.

$$\frac{\partial z}{\partial w} = \frac{\partial (x \cdot w + b)}{\partial w} = x$$
$$\frac{\partial z}{\partial b} = \frac{\partial (x \cdot w + b)}{\partial b} = 1 \quad (8)$$

$\frac{\partial L}{\partial \hat{y}}$ ise hata denkleminin türevinden denklem 9'daki gibi elde edilebilir.

$$\frac{\partial L}{\partial \hat{y}} = \frac{\partial ((\hat{y} - y)^2)}{\partial \hat{y}} = 2(\hat{y} - y) \quad (9)$$

Zincir türevler alınabilir olduğundan denklem 5 ve 6'daki türevler hesaplanabilmektedir. Bu türevler hesaplandıktan sonra ise hatayı azaltmak üzere geri yayılım denklem 10'da gösterildiği gibi, ağırlık w ve bias değeri b güncellenerek gerçekleştirilmektedir.

$$w \leftarrow w - \eta \cdot \frac{\partial L}{\partial w}$$
$$b \leftarrow b - \eta \cdot \frac{\partial L}{\partial b} \quad (10)$$

Denklem 10'da gösterilen η öğrenme oranı olarak adlandırılır ve her bir adımda yapılacak güncellemenin büyüklüğünü belirler.

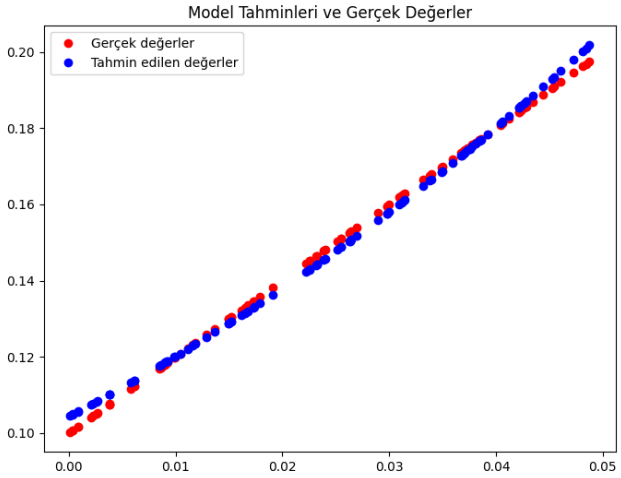
Yukarıdaki işlemler her eğitim iterasyonunda (epoch) tekrarlanır. Her iterasyonda:

1- İleri yayılım ile kayıp hesaplanır.

2- Geri yayılım ile ağırlıklar ve bias optimize edilir. Bu döngü, modelin tahmin hatasını minimize edene kadar devam eder.

IV. SONUÇLAR

Model, 500.000 epoch boyunca eğitilmiştir. Eğitim sonuncunda loss $4.02 * 10^{-6}$ olarak ağrılık w ve bias b parametreleri bulunmuştur. Model tahminleri ve gerçek değerler Şekil 2'de çizdirilmişitir.



Şekil 2: Model Tahminleri ve gerçek değerler

Şekil 2'de görüldüğü üzere, tahmin edilen değerler gerçek değerlerle tam olarak örtüşmemekle birlikte yüksek bir hassasiyetle yakınsamaktadır. Veriler doğrusal (lineer) bir ilişkiye sahip olsa da, sigmoid fonksiyonun kattığı doğrusal olmayan (nonlineer) yapı nedeniyle tahmin edilen değerler tam olarak gerçek değerlerle eşleşmemektedir. Bu durum, verinin işlenmeden önce doğru bir şekilde analiz edilmesinin önemini göstermektedir. Aslında, bu problem doğrusal regresyon (linear regression) yöntemiyle de yüksek doğrulukla çözülebilir.

KAYNAKÇA

[1] M. khalil Alsmadi, K. B. Omar, S. A. Noah, ve I. Almarashdah, "Performance Comparison of Multi-layer Perceptron (Back Propagation, Delta Rule and Perceptron) algorithms in Neural Networks", içinde *2009 IEEE International Advance Computing Conference*, Mar. 2009, ss. 296-299. doi: 10.1109/IADCC.2009.4809024.

[2] F.-L. Chung, S. Wang, Z. Deng, ve D. Hu, "CATSMLP: Toward a Robust and Interpretable Multilayer Perceptron With Sigmoid Activation Functions", *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, c. 36, sy 6, ss. 1319-1331, Ara. 2006, doi: 10.1109/TSMCB.2006.875871.