1 Giriş

Günümüz şehirlerde artan nüfus yoğunluğu şehir güvenliği gibi sorunları da beraberinde getirmiştir. Şehirler, şirket, kampüs alanları gibi alanlarda yaşanan yoğunluk sebebiyle güvenlik sorunları ortaya çıkmaktadır. Bu bağlamda insanların hareketleri arasındaki düzeni anlamak potansiyel tehlikeleri önceden tespit etmede büyük önem taşımaktadır. İnsanların oluşturduğu güzergahların yardımıyla anomalilerin tespit edilmesi oldukça önemlidir.

Trajectory clustering, rota verilerinin analiz edilerek örüntüleri ortaya çıkarmayı ve rotaların sınıflandırılmasını sağlayan bir yöntemdir. Bu proje, şehirlerde insanların hareket verilerinden yola çıkarak anomali tespit etmeyi ve bu süreçte trajectory clustering tekniklerinden faydalanmayı amaçlamaktadır. Hedef, olağan dışı davranışları (örneğin, yoğun olmayan bir bölgede anormal bir hareketlenme) tanımlamaktır.

2 Problem tanımı

Bu projede, insanların izlediği rotaların koordinat verileri olarak değil fakat state'ler ve state'ler arası geçiş süresi olarak tanımlanmıştır. Örnek bir rota verisi aşağıdaki gibi verilmiştir.

Cluster States = [Start, State 4, State 3, State 1, End]

State Times = [3.52, 2.35, 1.76, 1.68, 0]

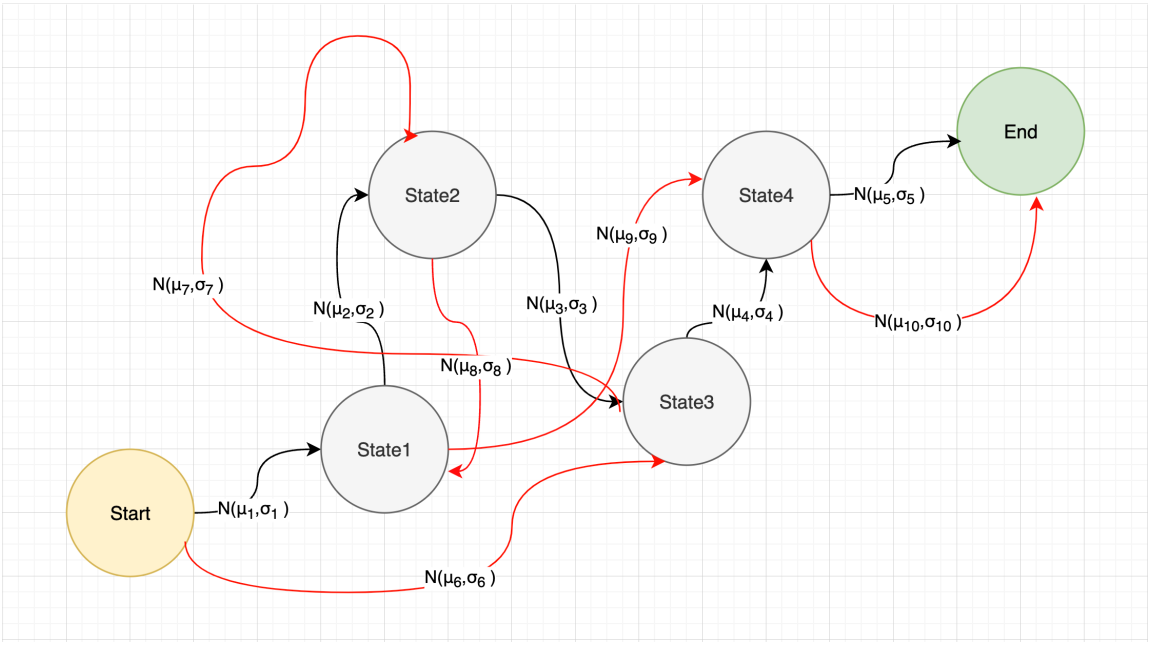
Rota verileri numaralandırılmış state'lerden ve her bir state'in diğer state'e geçiş zamanını içeren verilerden oluşmaktadır. Bu problemin çözümü, verilerin trajectory clustering yöntemi ile kümelendirilip kümelendirilmiş rotalar üzerinden test edilen rota verilerinin anomali olup olmadığının tespitini içermektedir.

3 Yöntem

3.1 Simülasyon ortamı: Cluster ve Kişi simülasyonu

Proje kapsamında çalışmalara başlanabilmesi için veri gereklidir. Bu veriyi elde edebilmek amacıyla bir simülasyon ortamı hazırlanmıştır. Bu amaçla, **ClusterGenerator** adında bir sınıf oluşturulmuştur. Sınıf, kişi sayısı (**num_people**), küme sayısı (**num_clusters**), her yoldaki adım sayısı (**steps_per_trajectory**) ve toplam durum sayısı (**number_of_states**) gibi parametreleri alarak çalışmaktadır.

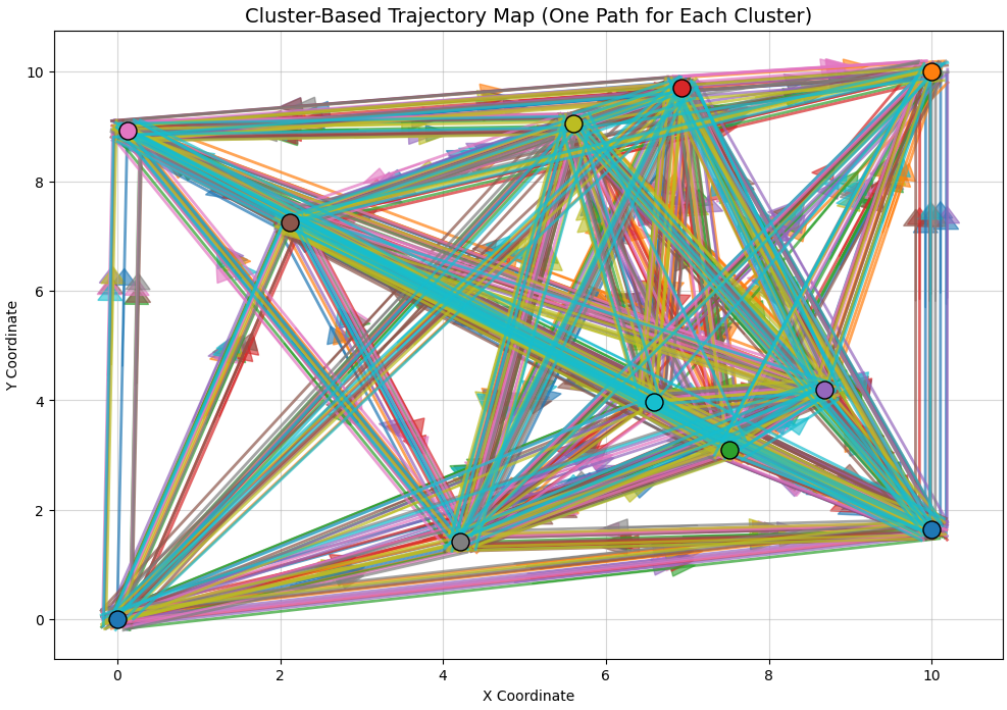
Bu parametreler kullanılarak öncelikle, her küme (cluster), belirtilen adım sayısı kadar durumlardan (state) oluşturulmaktadır. İki durum arasındaki geçiş süresi, rastgele bir Gauss dağılımı kullanılarak modellenmektedir. Bu şekilde, belirlenen küme sayısı kadar küme oluşturulmakta ve her iki adım arasındaki geçiş süreleri için kullanılan Gauss dağılımının ortalama ve varyans değerleri rastgele olarak belirlenmektedir. Örnek iki tane cluster Şekil 1'de gösterilmişitir.



Şekil 1: İki tane cluster örneği

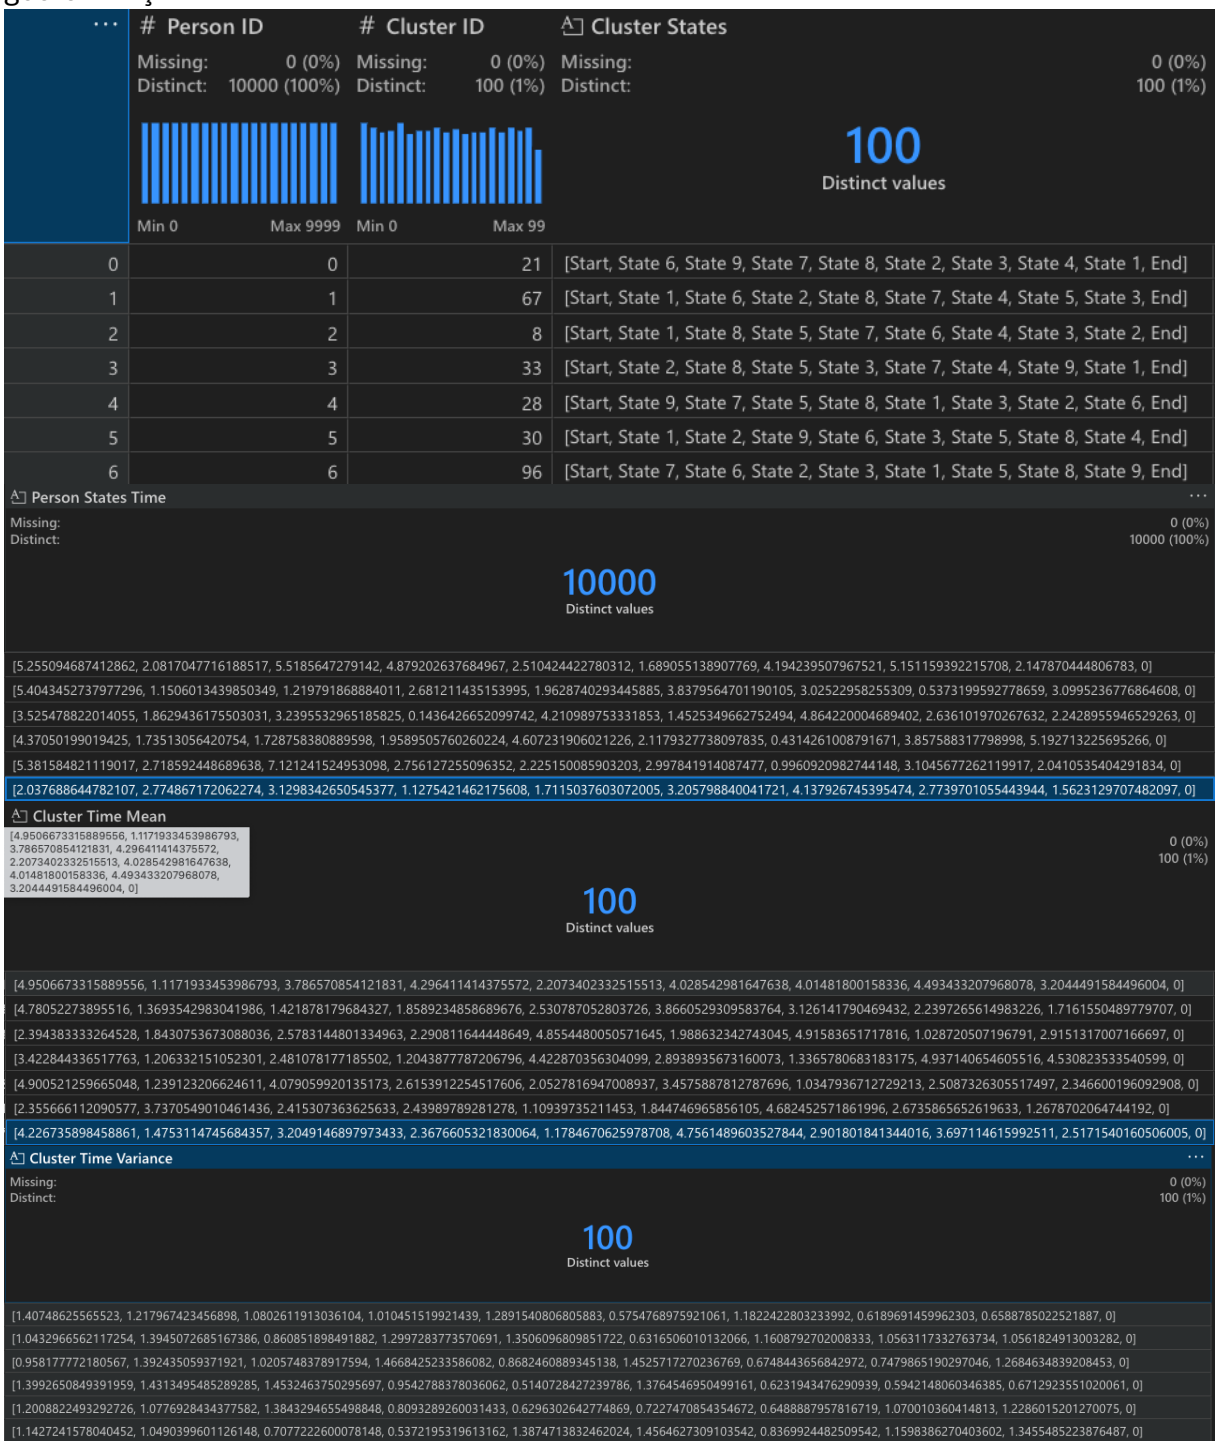
Daha sonra, bu kümelerden rastgele örnekleme yapılarak her bir kişi için izledikleri kümeler oluşturulmaktadır. Öncelikle bir başlangıç kümesi seçilmekte ve ardından kişinin izlediği yol belirlenmektedir. Her iki adım arasındaki geçiş süresi, ilgili kümenin iki adım arasındaki geçiş süresi için tanımlanan Gauss zaman dağılımından örneklenerek hesaplanmaktadır.

Problemi basitleştirmek adına, her kümenin ortak bir başlangıç noktasından başlayıp ortak bir bitiş noktasında sona erdiği varsayılmıştır. Ayrıca, yazılan görselleştirme özelliği sayesinde kümeler görsel olarak gösterilebilmektedir. Şekil 2'de bunun bir örneği sunulmuştur.



Şekil 2: Kişi verilerinin örneklendiği clusterlar (100 tane cluster ve 10 tane state)

Bulunan veriler csv dosyasına yazılmıştır, yazılan verilerden bir örnek Şekil 3'te gösterilmiştir.



Şekil 3: csv dosyasına kaydedilen veriler

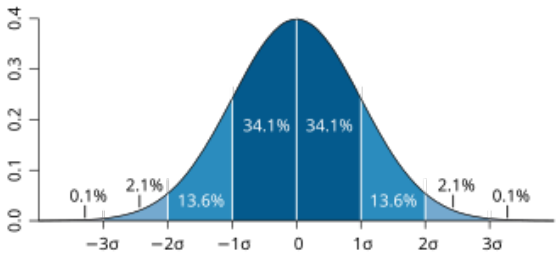
3.2 Sınıflandırma işlemi

Sınıflandırma işlemi sırasında, her bir sınıf için durumlar (state'ler) arasındaki geçiş sürelerinin ortalama ve varyanslarının hesaplanması gerekmektedir. Bu amaçla, CSV dosyasında bulunan '**Person States Time**' sütunundaki veriler işlenmiş, bu veriler üzerinden ortalama ve varyans hesapları yapılmıştır. Hesaplanan sonuçlar, ilgili değişkenlere kaydedilmiştir.

3.3 Anomali tespiti

Anomali tespiti yapılırken, gelen kişinin izlediği yolun kümelere (**clusters**) ne kadar benzediği veya ne kadar farklı olduğu belirlenmelidir. Daha önce hiç izlenmemiş bir yol, bir **anomali** olarak kabul edilmiştir. Eğer izlenen yol daha önce kümelerde tanımlanmış bir yolsa, bu durumda yoldaki her iki adım arasındaki geçiş süreleri incelenmektedir.

Her iki adım arasındaki sürenin, ilgili kümenin ortalamasından kaç standart sapma (σ) uzakta olduğu hesaplanmaktadır. Eğer bu mesafe 3 σ'dan daha fazla ise, bu durum bir anomali olarak sınıflandırılmaktadır. Bu yaklaşım, Şekil 3'te gösterilen Gauss dağılımının özelliklerinden yararlanmaktadır. Çünkü Gauss dağılımında 3 σ'dan daha uzak bir olayın gerçekleşme olasılığı yaklaşık %0.1'dir. Gauss dağılımı Şekil 4'te gösterilmişitir.



Şekil 4: Gauss dağılımı ve olasılık dağılımı fonksiyonu

Bahsi geçen adımları gerçekleştirmek için "**detect_anomality**" fonksiyonu yazılmıştır. State ve state geçiş zamanları verilen bir rota için fonksiyon, rotanın anomali mi değil mi olduğunu döndürür. Şekil 5'te görüldüğü gibi fonksiyonun girişine verilen rotanın ilk önce veri setinde bulunan rotalar arasında olup olmadığına bakar ve eğer veri setinde böyle bir rota yok ise bu rotanın bir anomali olduğunu döndürür. Eğer bu rota veri setinde mevcut ise fonksiyonun girişine verilen rotanın zaman verisi ile bu rotanın veri setindeki ortalama verisi arasındaki fark bulunarak rotanın ortalamadan ne kadar saptığı bulunur. Daha sonra bu sapma verisi varyansa bölünerek sapmanın σ cinsinden değeri bulunur. Son olarak bu sapma değerinin 3 σ'dan büyük olup olmama durumuna göre anomali olup olmadığı döndürülür.

```
detect_anomality(cluster = [ 1. , 2. , 3., 10. , 7.,  4. , 6. , 9. , 5. , 0.],
                 time = [1 ,3, 4, 2.47, 7, 1.9727,4.64, 2.7743, 1.35,  0.],
                 clusters = clusters,
                 clusters_means = clusters_means,
                 clusters_var = clusters_var)
```

✓ 0.0s Python

```
Anomali
[1.27710056e+00 7.28368862e-01 1.77901804e+00 7.36686623e-03
 4.89755271e+00 1.20500875e-05 3.43309391e-03 4.98529619e-05
 4.52611197e-03] σ (standard deviations) from the mean for each state transition
```

Şekil 5: detect anomality fonksiyonu örnek çıktısı